

Bevezetés a gépi tanulásba

DR. BOTZHEIM JÁNOS, GULYÁS LÁSZLÓ és NAGY BALÁZS
magyar nyelvű előadásai alapján

Utoljára frissítés: 2024. június 13.

Előszó

Ez a jegyzet a 2023/2024/2. tavaszi félévben készült, mely a *Bevezetés a gépi tanulásba* című tárgy **magyar nyelvű** előadásait dolgozza fel. Elsődleges forrásaim a levetített prezentációk voltak, valamint azon magyarázatok, melyek elhangoztak.

A jegyzet a szó szoros értelmében jegyzetnek minősül, azaz a magyarázatok messze nem olyan precízek, mint amilyeneket egy hivatalos egyetemi jegyzet megkövetelne, valamint a szerkezete is inkább vázlatpontokban foglaja össze tömörén a lényeget. Emiatt **semmiképp sem helyettesíti az előadás anyagait**, legfeljebb egy áttekinthetőbb összefoglalást biztosít.

Igyekeztem a legjobb tudásom szerint összeállítani a jegyzetet, ennek ellenére előfordulhatnak benne elgépelések, hibák, stb. Ha találsz illet, kérlek értesíts e-mailben a(z) ap3558@inf.elte.hu címen.

Sikeres felkészülést kívánok!

Kiss-Bartha Nimród

Rövidítések

- **GT** – gépi tanulás \iff ML – machine learning
- **MI** – mesterséges intelligencia \iff AI – artificial intelligence
- **RL** – megerősített tanulás (*reinforcement learning*)

Források

- [1.] Az előadás prezentációi (*Canvason elérhetők*)
- [2.] Valentinusz (Boda Bálint és mások) jegyzete (*angol nyelvű*) [[link](#)]
- [3.] BME-s jegyzet (*magyar nyelvű*) [[pdf](#)]

Tartalomjegyzék

1. Mesterséges intelligencia vs. gépi tanulás – Bevezető	4
1.1. Mi az a gépi tanulás?	4
1.2. Mióta létezik?	4
1.3. Mik a hátráltató tényezők?	4
1.4. Az MI értelmezése	5
1.5. Az MI történelme	6

2. Napjaink MI-je – Optimalizáció	7
2.1. Mitől optimalizáció?	7
2.2. Intelligens viselkedés	7
2.3. Mitől nehéz az optimalizáció?	9
2.4. Hogyan próbálkozhatunk?	9
3. Felügyelt tanulás	10
3.1. Felügyelet nélküli tanulás – visszatekintés	10
3.2. Felügyelt tanulás	10
3.3. A tanulás típusai	10
3.4. Mi az a felügyelt tanulás?	11
3.5. Problémák	11
3.6. Döntési fák	11
3.7. Regresszió	13
4. Neurális hálózatok	14
4.1. Biológiai és mesterséges neuronok	14
4.1.1. Biológiai neuronok	14
4.1.2. Mesterséges neuronok	14
4.2. Egyrétegű perceptronok	15
4.2.1. Lineáris szeparabilitás	15
4.2.2. Logikai kapuk	16
4.3. Perceptronok tanítása	17
5. Etikai és jogi kérdések az MI területén	21
5.1. Az MI eredményei és nem kívánt következményei	21
5.2. Az MI és a művészeti viszonya – Théâtre d'opéra spatial	21
5.3. Felmerülő gondok az adatbázisa kapcsán	22
5.4. Korábbi találkozásaink az MI-vel	22
6. Felügyelet nélküli tanulás	23
6.1. Fő különbségek a felügyelt tanulástól	23
6.2. Klaszterezés	23
6.2.1. Agglomeratív klaszterezés	24
6.2.2. Prototípus alapú klaszterezés (k -means clustering)	24
6.2.3. DBSCAN	27
6.3. Dimenziócsökkentés	27
7. Megerősített tanulás	28
7.1. Mi az a megerősített tanulás?	28
7.2. Háttere, ágazatai	28
7.3. Felépítése	29
7.4. Modell alapú RL – Markov döntési folyamat	30
7.5. Modellmentes RL – Mély RL algoritmusok	32
8. Biológiai alapú MI megoldások	34
8.1. title	34
8.2. Rajointelligence – példák, motivációk	34
8.3. Térbeli csoportosítás – spacial clustering	34
8.4. Legrövidebb utak	35
9. Evolúciós algoritmusok	35
9.1. Motiváció	35
9.2. title	35
9.3. Genetikus algoritmusok	36

10. Rajintelligencia	37
10.1. Bevezetés, motiváció	37
10.2. Particle swarm optimisation (részecske raj optimalizáció)	37
10.3. Simplified Swarm Optimisation	38
10.4. Szentjánosbogár algoritmus (firefly algorithm)	38
10.5. Gravitációs keresőalgoritmus	38
11. Etorobotika	38
11.1. Motiváció	39
11.2. Etorobotika	39
11.3. Etológiai mintánk	39
11.4. Etológiai kutatási folyamat	39
11.5. Kísérletek	40
12. Multiágens szimuláció és tanulás (Multi-agent simulation and learning)	40
12.1. Motiváció	40
12.2. Mikro- és makroviselkedés	41
12.3. Ágens alapú szimuláció	41
12.4. Multiágens megerősített tanulás	41

1. Mesterséges intelligencia vs. gépi tanulás – Bevezető

1.1. Mi az a gépi tanulás?

- fogalmak tisztázása: gépi tanulás (GT) \neq mesterséges intelligencia (AI)
- a két fogalom kapcsolódik egymáshoz, de nem ugyanarra vonatkoznak
 - az MI sokkal régebbre nyúlik vissza ('50-es évek)
 - a GT frissebb, az MI-ből alakult ki
 - (mondhatnánk, hogy $GT \subset AI$)
 - viszont mégis összekapcsolónak, ugyanis jelenleg a **mély gépi tanulás** (*deep machine learning*) uralja az MI-t

1.2. Mióta létezik?

- 1956 óta vannak ilyen célú kutatások
 - Dartmouth konferencia, ahol megjelentek az MI alapítói
 - azt kutaták, hogyan lehet mesterséges intelligenciát csinálni
 - másik szempontjuk, hogy hogyan lehet eladni
 - elnevezés: **mesterséges intelligencia** → marketing húzás (támogatók, szponzorok figyelmét felkeltsék vele)
- csak az elmúlt években robbant be a kutatási terület
 - a kutatások folyamatosak voltak '56 óta
 - csak az elért **eredményekről nem gondoljuk, hogy intelligensek**
 - a támogatás „hullámzó” volt (erről később)
- felmutatható **eredmények**
 - GPS, navigáció \leftarrow gráfkereső algoritmusok (BFS, DFS)
 - nyelvhelyesség-ellenőrző Wordben
 - postákon OCR (optikai karakterfelismerő) rendszerekkel szortírozzák a csomagokat már a '80-as évek óta (!)
 - szövegkövetkeztető (text prediction)

1.3. Mik a hátráltató tényezők?

- mi az az **intelligencia**? → nincs univerzálisan elfogadott definíció
 - olyan tulajdonság, amivel az ember rendelkezik... és mások?
 - egyetlen példából nehéz általánosítani
 - eddig „legjobb” megfogalmazás: egy olyan **gép**, hogy gép + digitalizáció = MI
- ezt a gépet az ember alkotja meg, hogy az *jobbá* váljon az embernél (jobban teljesítsen feladatakat nála)
 - mit jelent, hogy *jobban teljesítsen*?
 - pontosabban? gyorsabban? olcsóbban?
 - ilyen értelemben a varrógép is mesterséges intelligencia... ez kicsit kiábrándító

- a legtöbbször úgy épülnek be az életünkbe ezek az „intelligens” dolgok, hogy fel sem tűnik a létük
 - mintha egy közmű lenne
 - pl. az elektromosság megjelenésekor mindenki démonizálta az új technológiát, 100 évvel később anapság akkor pánikolunk, amikor nincs áram
 - hasonló érzelmek / gondolatok forognak az MI körül is

1.4. Az MI értelmezése

A) Szűk MI (narrow AI):

- jelenlegi korunk
- adott feladatot (feladatcsoportot) jobban csinál, mint az ember
- ekkor a szűk értelmezésben intelligensnek nevezhetők

B) Általános MI (AGI – artificial general intelligence)

- felülmúlja az emberi intelligenciát
- minden feladatot képes elvégezni

C) Egyéb elméleti koncepciók:

- szingularitás: fel sem tudjuk fogni a fejlődés mértékét (irodalmi művekből ered a fogalom)
- szuperintelligencia
- öntudatra ébredés (→ mi az az öntudat?)

A **vita** arról szól, hogy *még nem* vagy *már* eljutottunk-e az AGI-ba? Ennek előírására **teszteket** állítottunk elő.

1. Turing-teszt:

- ha lehet vele beszélgetni egy interfésze keresztül úgy, hogy 30 perc eltelte után nem tudjuk eldönteni, hogy ember-e vagy gép → a gép intelligens
- eredmény: elértek
- ChatGPT átmenne a teszten (szigorú értelemben nem, mert ha megkérdezzük tőle, hogy ő ember-e vagy gép, (egyelőre) gépet fog mondani)

2. Robot hallgató-teszt:

- (mármint egyetemi diákok)
- beíratjuk egy egyetemre; ha lediplomázik, mint egy hallgató → a gép intelligens
- eredmény: egyesek átmentek rajta

3. Employment test

- állást kereső robot; ha felveszik → intelligens
- nehéz tesztelni

4. Egyéb tesztek:

- IKEA-teszt: ha össze tud rakni egy IKEA-s bútor, akkor intelligens
- Kávé-teszt: ha tud készíteni kávét, akkor intelligens
 - a trükk a feladatban megvívó komplexitás

- sok a be nem számítható változó (polc magassága, hol találja a kávét, ismeri-e a ketyogós használatát, stb.)
- nem sikerült elérni semminem / senkinek

Praktikus dolgokban alulmaradnak, az ember jobb bennük.

1.5. Az MI történelme

- hullámokban érkeztek / érkeznek a fejlődések
- megoszlanak a nézetek, hány hullám volt / van
- kutatáspromócióra tökéletesen használható a terület ezen természete

1956-ban megszületik az **MI**, mint fogalom



hatalmas **támogatás**, érdeklődő hallgatók



de **nem** jelentek meg hasznosnak, *intelligensnek*
minősülő eredmények → az *első MI tél*

- 5-10 évvel később: fiatalabb kutatók újabb ötletekkel érkeztek
 - mantra: „az első társaság rosszul csinálta, de mi tudjuk”
 - ugyanúgy elbuktak
- most úljabb felfele ívelés tapasztalható
- a régebbi eredmények sosem tűntek el, csak nem MI-ként gontolunk rájuk (*ld. korában*)
- utolsó hullám eleje:
 - 2000-2001. – felismerték, hogy hétköznapi tudásra, „*józan észt*” igénylő feladatok megoldására, trivialitások felismerésére nem alkalmas
 - gondolat: „*ha meggondoljuk, a csecsemő és a gyerek is ezeket a trivialitásokat tanulja meg, amiig fel nem nő*”
 - projekt: Open Mind Common Sense
 - * az általános tudásunknak, a *józan észnek* az adatbázisa
 - * ilyeneket tartalmazott, pl. *az anyám anyja a nagyanyám*
 - minek összegyűjteni ezeket, ha ott az **internet**?



ezt felhasználva kapjuk meg a **gépi tanulást** → elérkeztünk napjainkig

2. Napjaink MI-je – Optimalizáció

Az előadás téTELmondata: az MI-kutatás (legtöbb) feladata az **optimalizáció**ról szól.

2.1. Mitől optimalizáció?

- példa: $f^* = \arg \max_{x \in X} f(x)$
- feladat: keressük azt az modellt, aminek a paramétereit (**súlyait**, jele $w \in W$) **a legjobban állítom be**, a legjobban teljesít általában minimumot keresünk
- jó = minimumtól való eltérés kicsi
- $f^* = \arg \min_{w \in W} f(w, x)$ (ahol w a tanult paraméterek és x a bemeneti példányok)
- valahol könnyebben látszik, valahol nehezebben látszik az optimalizáció (problémamegoldás) pl. legrövidebb A -ból B -be vezető út (lehetséges jelentései: legrövidebb számú lépéssorozat, legrövidebb úthossz, legrövidebb idő)

2.2. Intelligens viselkedés

Tipikus feladatok, amiket ha képes megoldani, intelligensként tekintünk rá.

A) Tervezés

- adott bizonyos lépések elvégzésének egy sorrendje → cél:
 - hogy a legtöbbet gyártsuk
 - hogy a legnagyobb legyen a haszon
- ha nem triviálisan kicsi a feladat, nem várhatjuk el, hogy az MI jobban teljesítsen

B) Kép- / hang- / szövegfelismerés

- pl. ismerje fel, hogy milyen betűt ábrázol a rajz
- megadunk egy **veszteségfüggvényt** / **hibafüggvényt** → cél: az ettől való eltérés minimalizálása

C) Tanulás

- kulcs: **fejlődés** (minden egyes iterációnál váljon jobbá a korábbi iterációhoz képest)
- pl. *darts célbabotása*: ha nagyon magasan van, vigye lejjebb, ha túl balra dob, jobbrább kell tolnom \Rightarrow **paraméterek finomhangolása**
- találja el a célpontot → vizsgálja meg az eredményt → változtasson a paramétereken (váljon jobbá)
- szintén, a célunk
 - hiba minimalizálása
 - pontosság maximalizálása
- feladat: határozzuk meg, hogy a *hibafüggvény az adott helyen hogyan fog változni*

↓

gradiens, deriválás

- gépi tanulás osztályai

(a) Felügyelt tanulás (*supervised learning*)

- tudjuk a jó választ
- az MI eredményét összehasonlíthatjuk vele (jó-e vagy sem, mennyire jó, stb.)
- *előfeltétel*: álljon a rendelkezésünkre sok példa / adat, amik meg vannak címkézve (**címkézett adat**) → ez a súlyállítgatás miatt fontos

(b) Felügyelet nélküli tanulás (*unsupervised learning*)

- címke nélküli adatunk van
- „*majd meglátjuk*” alapon derül ki a képessége
- pl. a '70-es évek óra így működtek a karakterfelismerő rendszerek → **klaszterezéssel** megállapítja, mennyire hasonlítanak
- van, hogy mi adjuk meg, hány csoportba rendezze a bemeneteket (pl. számjegyek esetén 10-et), VAGY rábízzuk, hogy saját maga fedezze fel ezeket a csoportokat
lehetséges probléma: a 9-es és a 6-os számjegyet azonosnak veszi

(c) Megerősítéses tanulás (*reinforcement learning*)

- régi ötletről van szó
- próbálja meghaladni a felügyeletet
- nincs címke, és adat sem igazán → helyette **visszacsatolás** van
- ha a visszacsatolás szerint helyes az eredmény, **jutalomban** részesül (*reward*)
- „*próba-szerencse*” (*trial and error*) alapjú
- példa: α_0 sakkjáték

- *megjegyzés*: a tanulás **lassú folyamat**

- felügyelt és megerősített tan.: sok számítás és futtatás
- felügyeletlen tan.: valamivel kevesebb
- ha meggondoljuk, az emberek is lassan tanulnak

D) Valami új generálása

- a tanulás alkalmazása a szoftver generatív aspektusában (Dall-E, ChatGPT, stb.)
- az alábbi gondolatok álnak mögötte

(a) Önkódoló rendszerek (*autoencoders*)

- az alábbiakra van szükségünk:

* adott egy bemenet és egy kimenet: $in, out \in \mathbb{R}^D$

* kódolós (*encoding*): $f : \mathbb{R}^D \rightarrow \mathbb{R}^d$, ahol $d \ll D$ ¹

* dekódolás (*decoding*): $g : \mathbb{R}^d \rightarrow \mathbb{R}^D$

* generatív kimenet (generative output): $g(y)$, ahol $y \in \mathbb{R}^d$ tetszőleges (random)

¹Jelentése: sokkal kisebb a dimenzionalitása d -nek D -hez képest

- az *ötlet mögötte*: van egy óriási dimenzionalitású adatunk → a kódoló f függvénytel lecsökkenjük a dimenzionalitását → az így kapott eredményt dekódoljuk a g -vel, hogy a bemenetivel azonos dimenzionalitású eredményt kapunk
- *cél*: úgy kódoljuk át a bemenetet, hogy az eredeti bemenet „jellegzetességeit” megőrizze
- olyan, *mint* a JPEG tömörítő algoritmus; hogy az ember számára nem látható részleteket eliminálja a képből, ezzel csökkentve a fájlmeretet
- *eredmény*: minél jobbak a leképezőfüggvényeink, annál jobban fog hasonlítani a vég-eredmény az eredeti bemenetre
- pl. arc generálása, javító algoritmusok

(b) *GAN – generative adversarial network*

- lehetséges magyar fordítása: generatív ellenfél hálózat
- példán keresztül szemléletve: adott két MI
 - * az egyiknek (*A* vagy **generátor**) a feladata: tanulja meg, hogyan kell bankjegyet hamisítani
 - * a másiknak (*B* vagy **diszkriminátor**) a feladata: tanulja meg felismerni a hamis bankjegyeket
 - * a két modell interakcióban van egymással
 - * kezdetben az *A* szörnyen teljesít, így a *B*-nek könnyű dolga van
 - * ahogy *A* egyre fejlődik, úgy válik *B*-nek a feladata nehezebbé
 - * ezt a módszert **generátor-diszkriminátor modellnek** is hívják

2.3. Mitől nehéz az optimalizáció?

- $f^* = \arg \min_{w \in W} (w, x)$ – jellemzően $W \subseteq \mathbb{R}^N$, ahol $N > 10^6$
- azaz *hatalmas a dimenzionalitás*, amivel dolgoznunk kell
 - nem egyértelmű, melyik súlyt finomhangoljuk
- nem gyakran folytonos / deriválható / monoton → csúnya függvények
 - más szóval „rücskös” függvények (*rugged functions*)
 - nem alkalmazhatók a jól ismert tteleink analízisból → nincs esélyünk megtalálni az egzakt szélsőértékeit
 - ezért **közelítenünk kell felé**

2.4. Hogyan próbálkozhatunk?

- a biológiából, a természetből inspirálódunk → **matematikai modellek**
 - agy → **mesterséges neurális hálók** (*artificial neural networks*)
 - evolúció → **evolúciós algoritmusok** (*evolutionary algorithms*)
 - társas rovarok → **raj intelligencia** (*swarm intelligence methods*)
- róluk később bővebben lesz szó

3. Felügyelt tanulás

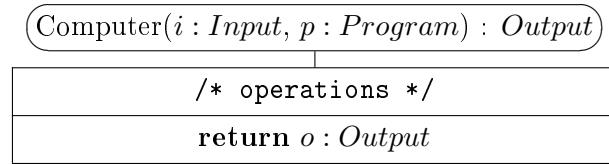
Más fordítások: ellenőrzött tanulás.

3.1. Felügyelet nélküli tanulás – visszatekintés

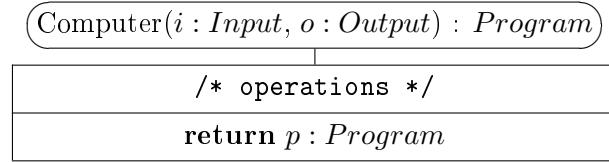
- nagy adathalmaz → megpróbál hasonlóságokat és különbségeket észrevenni → csoportosítás, klaszterezés
- nincs visszacsatolás a környezettől, nincs (számszerű) visszajelzés

3.2. Felügyelt tanulás

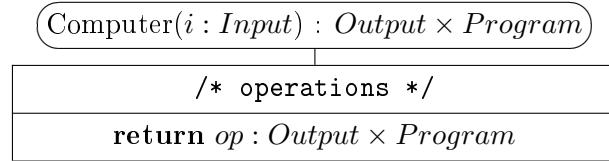
- van egy „tanító”, azaz az **adataink meg vannak címkézve**, ami egyfajta vissza jelzésül szolgál
- pl. **hagyományos számítógépes programozás**



- ehhez képest a **felügyelt tanulás**



- emberibb példa: „*mit csinál a gép*” feladattípus (2. osztályból) → a programra kell rájönni, ahol ismerjük a bemenetet és a kimenetet
- **felügyelet nélküli tanulás**: a visszacsatolás hiányzik (címkeinformáció) → sokkal nehezebbnek tűnik



3.3. A tanulás típusai

- **tanulás**: saját teljesítményünk fejlesztése megfigyelések alapján Machine Learning
- **gépi tanulás**: az MI „részhalma”, a számítógépes rendszerek a megfigyelendő adatokban található mintákból tanul
- tanulási feladatok
 - **klasszifikáció** (osztályozás): ahol egy véges halmaz a kimenet
 - **regressziós** : \mathbb{R} ahol a kimenet egy numerikus predikció, (numerikus) feladat
- (2. osztályos példa) hogyan jövünk rá a programra / az algoritmusra? → mintát fedezünk fel a bemenet és kimenet között ÉS / VAGY próbálkozunk (és ezt optimalizáljuk)
- a hiba segítségével lehet irányítani a tanítást → modell (függvény) \Rightarrow távolságfüggvény

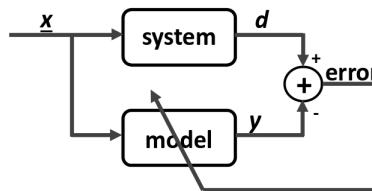
3.4. Mi az a felügyelt tanulás?

Adott egy N darabból álló **tanító adathalmaz** (*training data set*), mely

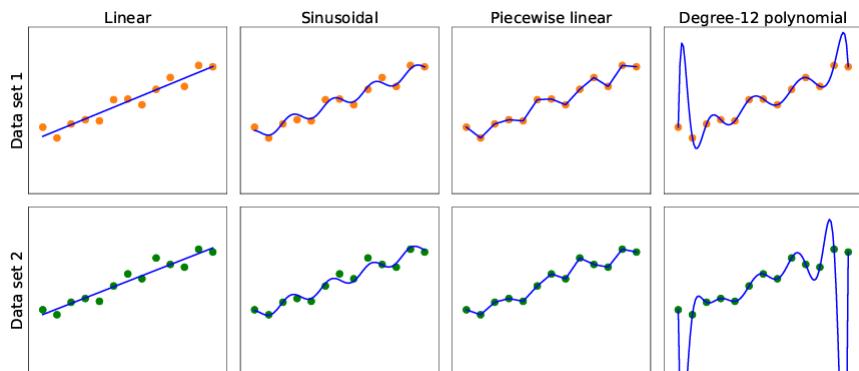
$$(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)$$

bemeneti-kimeneti párokból áll, melyeket egy ismeretlen $y = f(x)$ függvény generált. A feladat, hogy fedezzük fel a h függvényt (**hipotézist** – modellt), ami az igazi f függvényt közelíti.

- adottak bement-kimenet párosak: $x_1^{(p)}, \dots, x_n^{(p)}, d^{(p)}$
- p : a minták száma, n -dimenziós bemenet, skaláris kimenet
- x vektor → rendszeren és modellen keresztül → d és y



- a hiba vezérli a tanulást, és a hibát onnan tudjuk, hogy ismerjük a helyes kimenetet
- sokféle tanítási módszer létezik
- szemléletes példa: (x, y) pontpárokat adunk meg → találunk egy függvényt, ami átmegy ezeken a pontokon



- mi a baj ezzel a megközelítéssel? → túl specifikus az eredmény, más bemenet esetén nem lesz jó az eredményünk
- adathalmaz / tanítóminta – ne csak egy adott adatszettre illeszkedjen rá → **legyen jó az általánosítóképessége**

3.5. Problémák

- alulilleszkedés: túl egyszerű a modell, így nem jó az általánosító képessége
- túlilleszkedés: túl specifikus, szintén nem kezeli jól a tesztadatot

3.6. Döntési fák

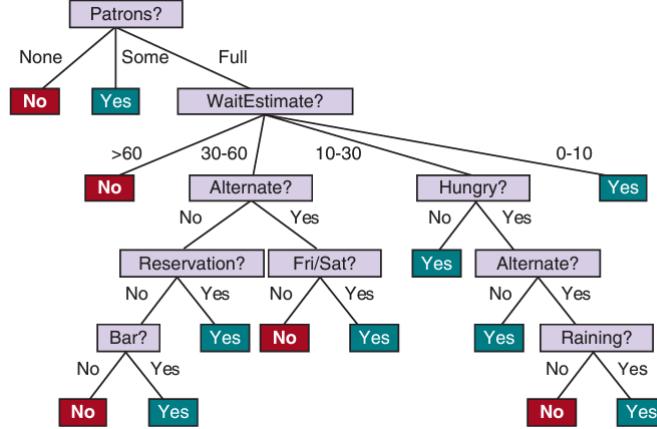
- fák egyes csúcsaiban egyes helyzetek vannak, ahol az élek egyes döntéseket jelentenek
- egy logikai döntési fára gondolhatunk így is:

$$\text{Output} \iff (Path_1 \vee Path_2 \vee \dots)$$

ahol az egyes *Pathok* (fagráfon utak) a gyökérből az egyes levelekbe vezető utakat jelölik (tehát, hogy igaz vagy hamis döntésre jutottunk az egyes lépésekkel követően)

- pl. éttermi várakozási probléma

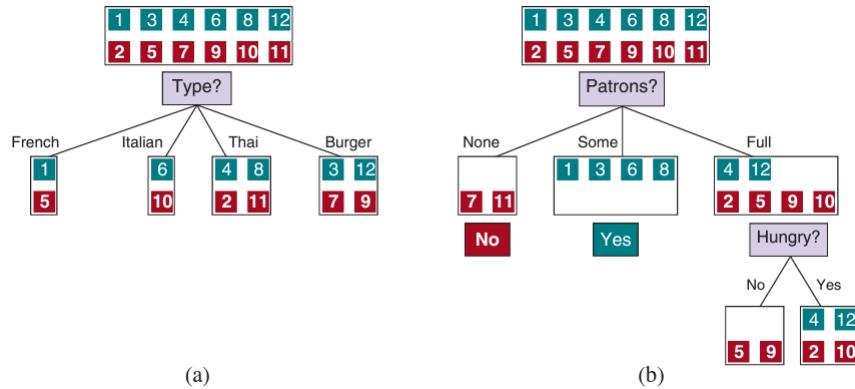
- rengeteg szempont felsorolva, mindenekhez tartozhat néhány eset
- a szerzők felállítottak egy döntési fát erre a szituációra



- mit csináljon, ha vannak információink nemcsak az inputról, hanem az outputról?
- az attribútumok alapján hogyan tudunk felépíteni egy fát?

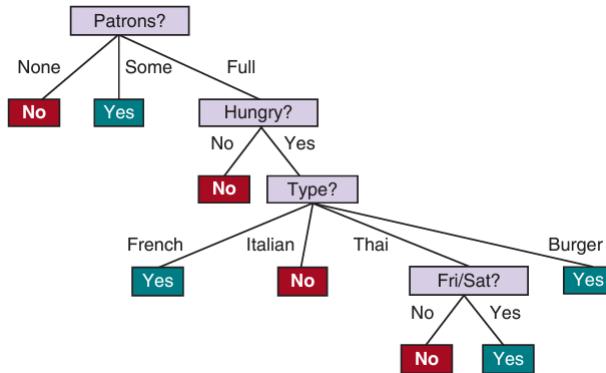
Example	Input Attributes										Output
	Alt	Bar	Fri	Hun	Pat	Price	Rain	Res	Type	Est	
X ₁	Yes	No	No	Yes	Some	\$\$\$	No	Yes	French	0-10	y ₁ = Yes
X ₂	Yes	No	No	Yes	Full	\$	No	No	Thai	30-60	y ₂ = No
X ₃	No	Yes	No	No	Some	\$	No	No	Burger	0-10	y ₃ = Yes
X ₄	Yes	No	Yes	Yes	Full	\$	Yes	No	Thai	10-30	y ₄ = Yes
X ₅	Yes	No	Yes	No	Full	\$\$\$	No	Yes	French	>60	y ₅ = No
X ₆	No	Yes	No	Yes	Some	\$\$	Yes	Yes	Italian	0-10	y ₆ = Yes
X ₇	No	Yes	No	No	None	\$	Yes	No	Burger	0-10	y ₇ = No
X ₈	No	No	No	Yes	Some	\$\$	Yes	Yes	Thai	0-10	y ₈ = Yes
X ₉	No	Yes	Yes	No	Full	\$	Yes	No	Burger	>60	y ₉ = No
X ₁₀	Yes	Yes	Yes	Yes	Full	\$\$\$	No	Yes	Italian	10-30	y ₁₀ = No
X ₁₁	No	No	No	No	None	\$	No	No	Thai	0-10	y ₁₁ = No
X ₁₂	Yes	Yes	Yes	Yes	Full	\$	No	No	Burger	30-60	y ₁₂ = Yes

- eddig csak kézzel építettük fel, most automatizáljuk a folyamatot
- precedenciát állítunk fel az attribútumok alapján; azaz lesznek fontosabb attribútumok (szempontok), amik előnyt élveznek a többivel szemben



- mikor fontosabb egy attribútum, ha jobban szeparálja az eseteket

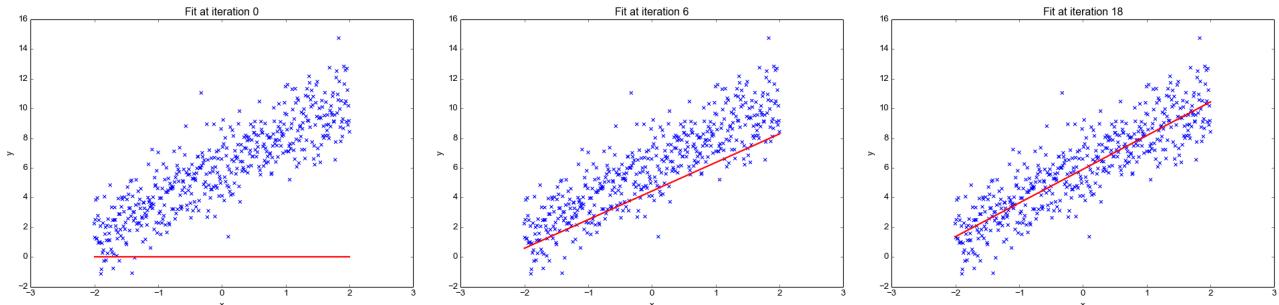
- ezt az algoritmust rekurzíve meghívjuk és így építjük fel a fát → optimális lesz az bemeneti adathalmaz szempontjából, megkapjuk, hogy optimálisan hogy jutunk el a legrövidebb úton a fa gyökeréből a csúcsba



- előnyei
 - könnyű megérteni
 - hatalmas adathalmazra is jól kiterjeszthető (scalability)
 - rugalmasan kezeli a véges és folytonos adatokat
 - klasszifikáció és regresszió egyszerre
- hátrányai
 - szuboptimális pontosság (főleg a mohó keresés miatt)
 - ha a fa mély, egy új előrejelzés nagyon költséges lehet egy új példánál
 - a döntési fák instabilak – egyetlen új példa hozzáadása a teljes fát megváltoztathatja

3.7. Regresszió

- feladat: egy lineáris függvényt hogyan illeszthetünk rá egy adathalmazra



4. Neurális hálózatok

4.1. Biológiai és mesterséges neuronok

4.1.1. Biológiai neuronok

- a biológiából jött a motiváció – ha ott működik, miért ne működne gépeknél is?
- **emberi idegrendszer:** egy nagyon összetett rendszer
 - *feladatai:* emlékezés, gondolkozás, problémamegoldás, döntéshozatal, stb.
 - *neuron:* jeleket kap meg más neuronuktól és ezeket kombinálja
 - * egy baba az agyában 10^{11} db. neuronnal születik
 - * egy neuron kb. 1000 neuronhoz van hozzácsatlakoztatva $\rightarrow 10^{14}$ db. kapcsolat (vagy él, ha gráf osztóból közelítjük meg)
 - * az emberi memóriakapacitás: 1 és 1000 TB között
 - ezek a jelek a *dendritek* mentén haladnak
 - ha a jel elég erős \rightarrow kimeneti jel az *axonon* keresztül más neuronokhoz
- felépítése
 - neuronok (idegsejtek) – 10^{11} darab van belőlük
 - átlagosan 100 összeköttetés per idegsejt \rightarrow 100 millió összesen
 - sejttest \rightarrow információ \rightarrow axon

4.1.2. Mesterséges neuronok

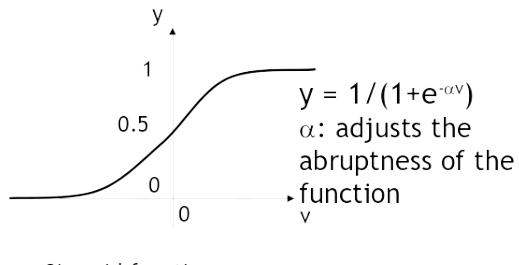
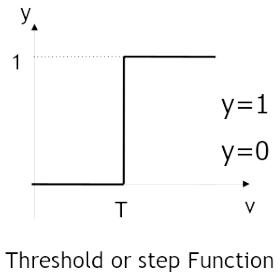
- az emberi agy és a számítógép összehasonlítása

	Számítógép	Emberi agy
<i>Sebesség</i>	4 GHz felett	40-50 Hz
<i>Működési mód</i>	sorosan (lineárisan)	párhuzamosan
<i>Ember felismerése</i>	bonyolult	könnyű ²

- az idegrendszernek egy egyszerűsített modelljét használjuk fel az MI-ben is
- **mesterséges neuron:** a bemenetek n -dimenziós *vektorok* $((x_1, \dots, x_n)$, ezek a), melyek *súlyokkal* rendelkeznek $((w_1, \dots, w_n))$, melyeket egy v értékben „összeadó csomópontban” (*summing junction*) számszerűsítünk. Ezeket átadjuk egy Φ függvénynek, ami visszaalakítja olyan formátumúvá, hogy bemenetként fel tudják használni más neuronok

$$((x_1, w_1), \dots, (x_n, w_n)) =: \mathbf{v} \mapsto \Phi(\mathbf{v}) := (y_1, \dots, y_n)$$

- önmagukban csak egyszerű feladatok megoldására képesek
- viszont ha elég sokat használunk fel belőlük, melyek össze vannak kötve egymással, képesek komplex feladatokat is megoldani
- **Φ – aktivációs függvény:** a kimenetet két aszimptota között korlátozza le, hogy a neuronok egy ésszerű, dinamikus intervallumon belül legyenek értelmezve
Tipikusan **lépcsős** (*step function*) vagy **szigmoid függvény** (*sigmoid function*) szokott lenni.



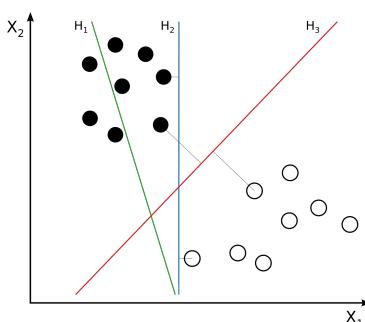
1. ábra. Lépcsős és szigmoid függvény

4.2. Egyrétegű perceptronok

- Rosenblatt vezette be 1958-ban, ez volt az első modell felügyelt tanulásra
- a McCulloch–Pitts-modellen alapult
- feladat: lineárisan szétválasztja (szeparálja) \Rightarrow **osztályozza az adathalmazt**
- előfeltétel: az adat legyen **lineárisan szeparálható**
- ezen limitáció miatt elapadt a lelkesedés iránta, de a '80-as években ismét elkezdtek érdeklődni a kutatók (napjainkban is fontosak)
- ennek továbbfejlesztett változata a *többrétegű perceptronok*, melyek lineárisan nem szeparálható mintákat is képesek csoportosítani

4.2.1. Lineáris szeparabilitás

- Matematikai jelentése: szerkesszünk egy hipersíket, amely kettéválasztja az adatokat úgy, hogy egy adat pontosan egy csoportba tartozhat (függvény grafikonja felett vagy alatt)
- Megjegyzés: kétdimenziós adatok esetén egyenest, n -dimenziós adathalmaz esetén $(n-1)$ -dimenziós hipersík lesz a szeparátorunk



2. ábra. A H_1 hipersík nem választja szét az adathalmazt, míg a H_2 és H_3 igen.

- Példa: vegyük két bemenetet: (x_1, x_2)
 - Megadhatunk-e rá egy szétválasztó egyenest?

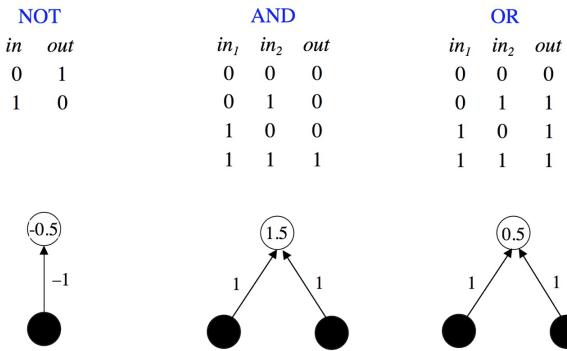
$$-w_0 + x_1 w_1 + x_2 w_2 = 0$$

- A perceptronok paramétereit **súlyoknak** (*weights*) hívjuk: w_1, w_2, \dots
- Mi az egyenlete?

$$x_2 = -\frac{w_1}{w_2}x_1 + \frac{w_0}{w_2}$$

4.2.2. Logikai kapuk

- Tipikusan kétváltozós, McCulloch-Pitts perceptronokkal megoldható feladat a logikai kapuk implementációja
- A **logikai függvények** (*boolean functions*), mint a \wedge (AND), \vee (OR) és a \neg (NOT) jól szeparálhatók lineárisan.³
- Mindegyik függvényre vannak bemeneteink: in_1 és in_2 , valamint egy out kimenet, melyekhez meg kell határozunk a súlyokat és a küszöbértéket



3. ábra. A NOT, AND és OR függvények implementációja

- Vannak azonban olyan függvények, amelyekhez kézzel nem szerkeszthetünk ilyen hálózatot. Ilyen például az XOR



4. ábra. Az XOR-hoz nem tudunk megfelelő súlyokat megadni

- Mindegyik **tanítóminta** (*training pattern*) lineáris egyenlőtlenségeket állít elő a kimenet számára, melyek a hálózat bemeneteiből és a hálózat paramétereiből állnak \rightarrow ebből kiszámíthatjuk a súlyokat és a küszöbértéket
- A következő egyenlőséget kell kielégítenie:

$$out = \text{sgn}(w_1 \cdot in_1 + w_2 \cdot in_2 - \theta).$$

in_1 in_2 out 0 0 0 0 1 0 1 0 0 1 1 1	$w_1 0 + w_2 0 - \theta < 0$ $w_1 0 + w_2 1 - \theta < 0$ $w_1 1 + w_2 0 - \theta < 0$ $w_1 1 + w_2 1 - \theta \geq 0$	\Rightarrow \Rightarrow $\theta > 0$ $w_2 < \theta$ $w_1 < \theta$ $w_1 + w_2 \geq \theta$
---	---	---

5. ábra. Az AND-hez tartozó egyenlőtlenségrendszer

³**Megjegyzés.** Összesen $2^4 = 16$ darab logikai függvény van, viszont a felsorolt 3-ból (\wedge , \vee és \neg) kirakhatjuk az összes többi is.

- Láthatjuk, hogy végtelen sok megoldásunk lehet. Hasonló igaz ez a NOT-ra és az OR-ra is.
- Ha a fenti egyenlőtlenséget elvégezzük az XOR-ra \rightarrow a 2. és a 3. ellent mond a 4. egyenlőtlenséggel, így nincs megoldása a feladatnak (hátránya a perceptronoknak)

$$\begin{array}{c}
 \begin{array}{|c|c|c|} \hline
 in_1 & in_2 & out \\ \hline
 0 & 0 & 0 \\ \hline
 0 & 1 & 1 \\ \hline
 1 & 0 & 1 \\ \hline
 1 & 1 & 0 \\ \hline
 \end{array} \Rightarrow \begin{array}{|c|} \hline
 w_1 0 + w_2 0 - \theta < 0 \\
 w_1 0 + w_2 1 - \theta \geq 0 \\
 w_1 1 + w_2 0 - \theta \geq 0 \\
 w_1 1 + w_2 1 - \theta < 0 \\ \hline
 \end{array} \Rightarrow \begin{array}{|c|} \hline
 \theta > 0 \\
 w_2 \geq \theta \\
 w_1 \geq \theta \\
 w_1 + w_2 < \theta \\ \hline
 \end{array}
 \end{array}$$

6. ábra. Az AND-hez tartozó egyenlőtlenségrendszer

- komplexebb hálózatokra lenne szükségünk, vagyis olyanokra, melyek több kisebb hálózatot kombinálnak; vagy egy másik aktivációs függvényt kellene használnunk
- akárhogy is, bonyolultabbá válik a küszöbérték és a súlyok meghatározása papíron

4.3. Perceptronok tanítása

- angolul: **training of perceptrons** (itt: *tanítás*, esetleg *kiképzés*)

A perceptronok tanításának algoritmusai.

I.) Incializáció

- állítsuk be a kezdeti értékeit a **súlyoknak**: w_1, w_2, \dots, w_m
- állítsunk be egy θ **küszöbértéket** egy random számra $a(z) \theta \in \left[-\frac{1}{2}, \frac{1}{2}\right]$ intervallumból
- állítsuk be a η **tanulási rátát** egy pozitív számra úgy, hogy $\eta < 1$

II.) Aktiváció

- számítsuk ki a p -edik iteráció **tényleges kimenetét**

$$y = \Phi \left(\sum_{i=1}^m x_i \cdot w_i \right)$$

- aktivációs függvény: **küszöbérték / lépésfüggvény** (vagy előjelfüggvény)

$$y(p) = step \left[\left(\sum_{i=1}^m x_i \cdot w_i \right) - \theta \right]$$

III.) Súlyok tanítása: a perceptronok súlyainak frissítése

- új súlyok:

$$w_i(p+1) = w_i(p) + \Delta w_i(p)$$

- súlykorrekció:

$$\Delta w_i(p) = \eta \cdot x_i(p) \cdot e(p)$$

- hiba (*error*):

$$e(p) = d(p) - y(p)$$

IV.) Iteráció: inkrementáljuk egyesével a p -t, térjünk vissza a II. lépéshöz és ismételjük a folyamatot a konvergenciáig

Példa az algoritmusra: perceptronok tanítása a logikai „és” műveletére.

Az epochnak 4 lehetséges bemeneti mintája van:

$$00, 01, 10, 11.$$

Kezdeti súlyok:

$$w_1 := 0,3 \text{ és } w_2 := -0,1.$$

Küszöbérték: $\theta := 0,2$. Tanulási ráta: $\eta := 0,1$.

Epoch	Ite-ráció	Bemenetek		Kezdeti súlyok		Elvárt kimenet	Tényleges kimenetek	Hiba	Végleges súlyok	
	p	$x_1(p)$	$x_2(p)$	$w_1(p)$	$w_2(p)$	$d(p)$	$y(p)$	$e(p)$	$w_1(p+1)$	$w_2(p+1)$
1	1	0	0	0,3	-0,1					
	2	0	1							
	3	1	0							
	4	1	1							

7. ábra. 1. lépés – Initializáció

Tényleges kimenetek:

$$y(p) = y(1) = \text{step} \left[\left(\sum_{i=1}^m x_i \cdot w_i \right) - \theta \right] = \text{step} [(0 \cdot (0,3) + 0 \cdot (-0,1)) - 0,2] = \text{step} (-0,2) = 0$$

Epoch	Ite-ráció	Bemenetek		Kezdeti súlyok		Elvárt kimenet	Tényleges kimenetek	Hiba	Végleges súlyok	
	p	$x_1(p)$	$x_2(p)$	$w_1(p)$	$w_2(p)$	$d(p)$	$y(p)$	$e(p)$	$w_1(p+1)$	$w_2(p+1)$
1	1	0	0	0,3	-0,1		0			
	2	0	1							
	3	1	0							
	4	1	1							

8. ábra. 2. lépés – Aktiváció

Az „és” műveletre a 00 bemenetekre 0 lesz az eredmény.

Hiba:

$$e(p) = e(1) = d(1) - y(1) = 0 - 0 = 0.$$

Epoch	Ite-ráció	Bemenetek		Kezdeti súlyok		Elvárt kimenet	Tényleges kimenetek	Hiba	Végleges súlyok	
	p	$x_1(p)$	$x_2(p)$	$w_1(p)$	$w_2(p)$	$d(p)$	$y(p)$	$e(p)$	$w_1(p+1)$	$w_2(p+1)$
1	1	0	0	0,3	-0,1	0	0	0		
	2	0	1							
	3	1	0							
	4	1	1							

9. ábra. 3. lépés – Súlyok tanítása (1/2)

Megjegyzés. Az „epoch” kifejezés szó szerint *kort*, *korszakot* jelent. Szinonimaként a GT témakörében még generációnak (*generation*) is nevezik, leginkább az evolúciós algoritmusok esetében. Arra utal, hogy „hányadik generációs fejlettségben” van az adathalmaz. Nem vagyok benne biztos, hogyan szokták lefordítani a magyar szakirodalomban, így inkább az angol megfelelőjét választottam.

Az új súlyok kiszámítása.

$$\begin{aligned}\Delta w_1(p) &= \Delta w_1(1) = \eta \cdot x_1(1) \cdot e(1) = 0, 1 \cdot 0 \cdot 0 = 0 \\ \Delta w_1(p+1) &= w_1(1) + \Delta w_1(1) = 0, 3 + 0 = 0, 3 \\ \Delta w_2(p) &= \Delta w_2(1) = \eta \cdot x_2(1) \cdot e(1) = 0, 1 \cdot 0 \cdot 0 = 0 \\ \Delta w_2(p+1) &= w_2(1) + \Delta w_2(1) = (-0, 1) + 0 = -0, 1\end{aligned}$$

Epoch	Iteráció	Bemenetek		Kezdeti súlyok		Elvárt kimenet	Tényleges kimenetek	Hiba	Végeleges súlyok	
	p	$x_1(p)$	$x_2(p)$	$w_1(p)$	$w_2(p)$	$d(p)$	$y(p)$	$e(p)$	$w_1(p+1)$	$w_2(p+1)$
1	1	0	0	0, 3	-0, 1	0	0	0	0, 3	-0, 1
	2	0	1							
	3	1	0							
	4	1	1							

10. ábra. 3. lépés – Súlyok tanítása (2/2)

Innentől $p := p + 1 = 2$. Ismételjük a 2-3-4. lépéseket, ameddig el nem kezd konvergálni.

Epoch	Iteráció	Bemenetek		Kezdeti súlyok		Elvárt kimenet	Tényleges kimenetek	Hiba	Végeleges súlyok	
	p	$x_1(p)$	$x_2(p)$	$w_1(p)$	$w_2(p)$	$d(p)$	$y(p)$	$e(p)$	$w_1(p+1)$	$w_2(p+1)$
1	1	0	0	0, 3	-0, 1	0	0	0	0, 3	-0, 1
	2	0	1	0, 3	-0, 1					
	3	1	0							
	4	1	1							

11. ábra. 4. lépés – Iteráció

Epoch	Iteráció	Bemenetek		Kezdeti súlyok		Elvárt kimenet	Tényleges kimenetek	Hiba	Végeleges súlyok	
	p	$x_1(p)$	$x_2(p)$	$w_1(p)$	$w_2(p)$	$d(p)$	$y(p)$	$e(p)$	$w_1(p+1)$	$w_2(p+1)$
1	1	0	0	0, 3	-0, 1	0	0	0	0, 3	-0, 1
	2	0	1	0, 3	-0, 1	0	0	0	0, 3	-0, 1
	3	1	0	0, 3	-0, 1	0	1	-1	0, 2	-0, 1
	4	1	1	0, 2	-0, 1	1	0	1	0, 3	0, 0

12. ábra. 1. epoch végeredménye

Epoch	Itéráció	Bemenetek		Kezdeti súlyok		Elvárt kimenet	Tényleges kimenetek	Hiba	Végeleges súlyok	
	p	$x_1(p)$	$x_2(p)$	$w_1(p)$	$w_2(p)$	$d(p)$	$y(p)$	$e(p)$	$w_1(p+1)$	$w_2(p+1)$
2	5	0	0	0,3	0,0	0	0	0	0,3	0,0
	6	0	1	0,3	0,0	0	0	0	0,3	0,0
	7	1	0	0,3	0,0	0	1	-1	0,2	0,0
	8	1	1	0,2	0,0	1	1	0	0,2	0,0

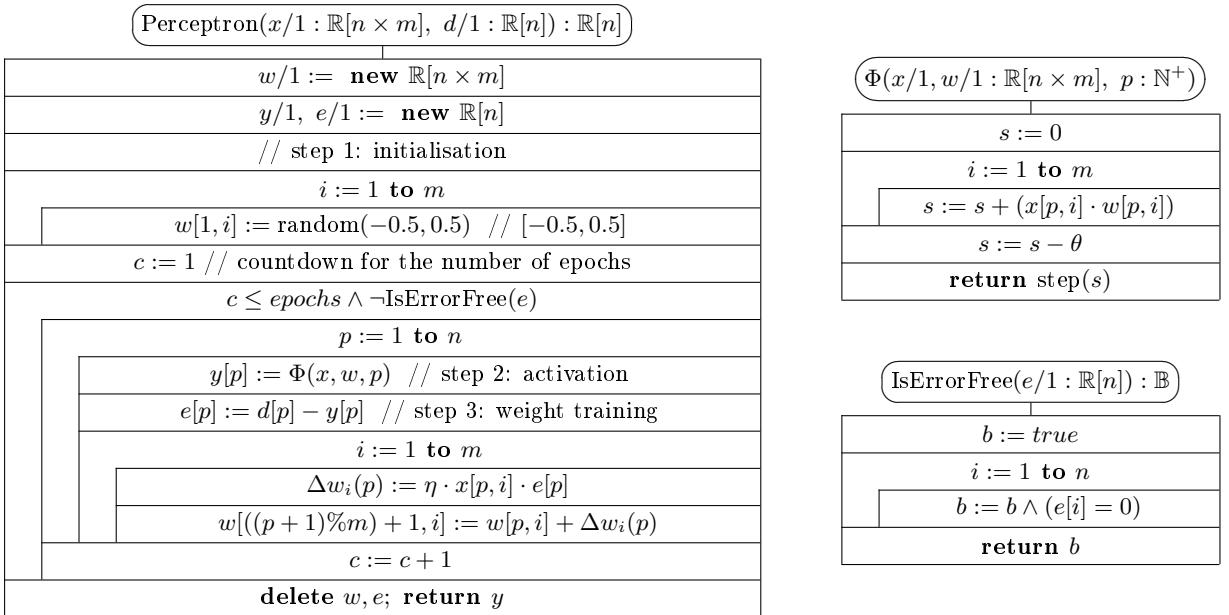
13. ábra. 2. epoch végeredménye

Epoch	Itéráció	Bemenetek		Kezdeti súlyok		Elvárt kimenet	Tényleges kimenetek	Hiba	Végeleges súlyok	
	p	$x_1(p)$	$x_2(p)$	$w_1(p)$	$w_2(p)$	$d(p)$	$y(p)$	$e(p)$	$w_1(p+1)$	$w_2(p+1)$
5	17	0	0	0,1	0,1	0	0	0	0,1	0,1
	18	0	1	0,1	0,1	0	0	0	0,1	0,1
	19	1	0	0,1	0,1	0	0	0	0,1	0,1
	20	1	1	0,1	0,1	1	1	0	0,1	0,1

14. ábra. 5. epoch végeredménye

- Ilyen feladat szerepelhet a vizsgán!
- Bebizonyították, hogy ezzel az algoritmussal bármely kétosztályosan szeparálható feladatra adható egy szétválasztó hipersík (ami két osztály esetén egy egyenes).
- A konvergencia gyorsasága sok mindenről függ: a sorrendtől, a küszöbértékektől (egyes θ értékekre jobban konvergál), stb.
- A back-propagation algoritmussal több perceptronról összerakhatnak hálózatba

A következő struktogramm csak vázlatosan szemlélteti az algoritmust. Feltételezzük, hogy az egyes paraméterek, mint az $epochs : \mathbb{N}^+$, $\theta : [-0.5, 0.5]$ és $\eta : \mathbb{R}$ változók globálisak. A pontos implementációs részleteket (globális változók, helyes inicializáció, függvényparaméter-átadás érték, cím vagy referencia szerint, stb.) az Olvasóra bízzuk.



5. Etikai és jogi kérdések az MI területén

5.1. Az MI eredményei és nem kívánt következményei

- az MI létrejöttének elsődleges motivációja az emberek minden napjainak könnyebbé, kényelmesebbé tétele
 - technológiai áttörések (pl. navigációs és GPS, stb.)
 - monoton feladatok automatizációja → hatékonyseg növelése
 - kutatásfejlesztésben áttörések ennek köszönhetően
 - (meg csomó példát lehet mondani, hamar össze tud szedni ilyeneket az ember)
- Center for Humane Technology
 - alapítói: Tristan Harris, Aza Raskin
 - mindenketten az MI etikai kérdéseivel, következményeivel foglalkoznak (*ethicist*)
 - **az MI-dilemma** (*the AI dilemma*): a tudományág és a technológia fejlődésének mértéke beláthatatlan mértéket ölt, így a friss innovációk olyan következményeket vonhatnak maguk után, melyekre nincs felkészülve a társadalunk
 - * az emberi kép- és hanggenerálás hamar megérkezett, az eredményük minősége gyakran megkülönböztethetetlen a valós nyersanyagtól → a hang és kép alapú bizonyítékok elavulttá, használhatatlanná váltak az igazságszolgáltatásban
 - * széles körben elérhetővé vált a generatív MI, emiatt felhasználhatjuk saját szolgáltatásaink (pl. rúter meghekkelésére írunk programot), intézményeink kijátszására (pl. autoriter rezsimek manipulációja)
 - * jogilag teljesen érintetlen, korlátozások nélküli területek, esetek
 - videók az MI-dilemmáról
 - * <https://www.youtube.com/watch?v=xoVJKj81cNQ&t=203s>
 - * https://www.youtube.com/watch?v=cB0_-qKba14&t=1163s
- egyre többen használják fel képzőművészeti célokra az eszközt
 - MI-generálta zenei videó: <https://www.youtube.com/watch?v=uG8vItscFKc>

5.2. Az MI és a művészet viszonya – Théâtre d'opéra spatial

- 2022, Colorado State Fair: éves szépművészeti verseny
- Jason Michael Allen a fotomanipulációs kategóriában nevezett egy MI-generálta képpel
- a Midjourney platformával készült; az első MI-generálta kép, ami **díjat nyert**
- hatalmas közfelháborodás a sajtóban
- felmerül egy csomó kérdés
 - Művészettel számít-e az MI által generált anyag?
 - A szerzői jog kit illet meg? Az utasítás (*prompt*) kiadóját vagy a platformot szolgáltató céget?
 - El fogja venni az emberek munkáját?
 - Eszközöként vagy veszélyes vetélytársként tekintsünk rá? (→ az érem két oldala)



15. ábra. Jason Michael Allen – Théâtre d'opéra spatial

5.3. Felmerülő gondok az adatbázisa kapcsán

- generatív mechanizmus: **generátor-diszkriminátor** modell → ha ugyanazzal az adathalmazzal dolgoznak, könnyen **beszennyezhetik egymás adathalmazát** → torz eredményt kaphatunk
- a GPT (*generative pre-trained transformer*) a teljes internetet felhasználja, de **nem jelöli meg a forrásait**, ami alapján generálta a tartalmat (pl. szöveget) → plagizálás, másolás?
 - a jegyzet írása idején (2023/2024/2. félév) egyes GPT modellek elkezdtek erre odafigyelni, pl. a Bing Copilot megjelöli a forrásait
 - kapcsolódó probléma: internetre kiengedve hamar rasszistává vált a ChatGPT → Ki a felelős érte? A cég? A termék? Kit lehet felelősségre vonni?

5.4. Korábbi találkozásaink az MI-vel

- a technológia 3 szabálya
 1. Amikor feltalálunk egy új technológiát, az új felelősségek osztályát fogja felfedni.
(*When you invent a new technology, you uncover a new class of responsibilities.*)
 2. Ha a technológia hatalmat ruház át, az versenyt indít.
(*If the tech confers power, it starts a race.*)
 3. Ha nem koordináljuk, a verseny tragédiába fulladhat.
(*If you do not coordinate, the race ends in tragedy.*)
- első MI, amivel az ember találkozott: **sülik a weblapokon, social media** (adatgyűjtés, amit ellenünk használtunk fel) → profilozás megindult, csoportra szabott reklámok

↓

csomó új negatív káros hatás jelent meg, ami ránk is hatássak van
(doomscrolling, polarizáció, stb.)

↓

adatalapú érdeklődés-fenntartás (*data-based engagement maximisation*)

- második találkozás az MI-vel:

- 2017-ig **generatív MI**; megszabott területeken lehetett hozzáérni (robotika, beszédfelismerés és -szintézis, zene- és képgenerálás, stb.)
- 2017-ben **transzformer modellek** megjelennek
- 2017 után; nyelvfeldolgozás, **generatív nagy multimodális nyelvi modellek** (*generative large language multimodal models*, GLLMM)

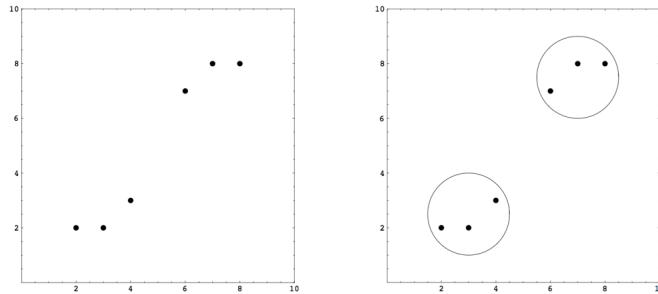
6. Felügyelet nélküli tanulás

6.1. Fő különbségek a felügyelt tanulástól

- **nincsenek címkék** (néha még az adat osztályai és jellemzői sem ismertek)
- **tipikus feladatok**: csoportosítások, hasonlóságok-különbözőségek felismerése (klaszterezés)
- **stratégiaiák**: **klaszterezés** (*clustering*) és **dimenziócsökkentés** (*dimensionality reduction*)

6.2. Klaszterezés

- **klasszifikáció** (felügyelt tanulás): esetén különböző típusú (címkekű) adathalmazunk van és szabályt állít fel, ami az adathoz hozzárendeli az osztályt
- **klaszterezés** (felügyelet nélküli tanulás): hasonló elemek milyen közel vannak egymáshoz, az adatok szerkezetét azonosítja
- **klaszter**: adatok egy csoportja, melyre teljesül, hogy
 - az azonos klaszterbe tartozó pontok jobban hasonlítanak egymásra, közelebb vannak egymáshoz
 - az eltérő klaszterekbe tartozók jelentősen eltérnek egymástól



16. ábra. Klaszterek

- **előnyei**: nincs szükségünk címkékre; néha nem is ismerjük az osztályokat vagy azok jellemzőit; csökkenthetjük vele az adatok számát
- **alkalmazásai**: kép- és jelfeldolgozás, adatelemzés, piacelemzés, tartalommenedzsment
- **elvárások, előfeltételek**
 - n darab p -dimenziós adat ($x_i \in X_1 \times \dots \times X_p$ (ahol $i \in [1..n]$))
 - k darab **nemüres klasztert** (*részalmazt* vagy *partíciót*) határozzunk meg, melyeknek uniója megadja az alaphalmazt és páronként diszjunktak

$$\begin{aligned} \forall i \in [1..k], C_i &\subseteq X : C_i \neq \emptyset \\ \forall i, j \in [1..k], i &\neq j : C_i \cap C_j = \emptyset \\ \bigcup_{i=1}^k C_i &= X \end{aligned}$$

- **típusai**: agglomeratív klaszterezés, prototípus alapú klaszterezés (pl. k -közepű klaszterezés), DBSCAN
- nincs univerzális megoldás, gyakran az adathalmaztól függ a megfelelő stratégia választása

6.2.1. Agglomeratív klaszterezés

- angolul: SAHN = *sequential agglomerative hierarchical non-overlapping clustering*
- algoritmus
 - n darab adatot n különböző klaszterbe soroljuk
 - ezután iteratívan összevonogatjuk a két „legközelebb állókat” (ez lehet *minimum*, *maximum*, *átlag* távolság, stb.)
 - addig folytatjuk, ameddig egy klasztert nem kapunk
- előnyei
 - nem egy partíciót, hanem partíciók sorozatát hozzuk létre
 - nem kell előre meghatároznunk a klaszterek, partíciók számát
- hátránya: a legtöbb ilyen módszer
- az algoritmus matematikailag precíz leírása

1. lépés: adott $\{x_1, \dots, x_n\} \subseteq R^p$ és $d : R^p \rightarrow \mathbb{R}$ egy távolságmetrika
2. lépés: kezdetben: $k_0 := n$, $\Gamma_0 := \{C_{0,1}, \dots, C_{0,k_0}\} = \{\{x_1\}, \dots, \{x_n\}\}$
3. lépés: $\forall i \in [0..(n-1)], \exists (a, b) \in \mathbb{N} \times \mathbb{N} : \min d(C_{i,a}, C_{i,b})$

$$\Gamma_{i+1} := \left(\Gamma_i \setminus \{C_{i,a}, C_{i,b}\} \right) \cup \{C_{i,a} \cup C_{i,b}\}$$

4. lépés: kimenet: $\Gamma_0, \dots, \Gamma_{n-1}$

6.2.2. Prototípus alapú klaszterezés (*k-means clustering*)

- nem az összes adat tartozhat klaszterekbe
- helyette, mindegyik C_i klaszterhez hozzárendelünk egy v_i pontot az adattérben (ezt jellemzően a **klaszter középpontjának** hívjuk)
- az egyes adatpontok abba a klaszterbe tartoznak, melynek a középpontjához áll a legközelebb:

$$\|x_k - v_i\| = \min_{j=1}^K \|x_k - v_j\| \implies x_k \in C_i.$$

- a klaszterezés során egy **partíciómátrix** jön létre

$$U = \begin{pmatrix} u_{11} & \cdots & u_{1n} \\ \vdots & \ddots & \vdots \\ u_{K1} & \cdots & u_{Kn} \end{pmatrix} \quad u_{ik} = \begin{cases} 1 & (x_k \in C_i) \\ 0 & (x_k \notin C_i) \end{cases}$$

- további megállapítások a partíciómátrix koordinátáiról
 - az adathalmaz összes pontja eleme valamely i -edik klaszternek: $\sum_{i=1}^K u_{ik} = 1$
 - nincsen üres klaszter: $\sum_{k=1}^n u_{ik} > 0$
- a prototípus alapú klaszterezések egyik leggyakoribb algoritmusa:

***k*-közpű klaszterezés (*k-means clustering*)**

- a neve onnan jön, hogy megmondjuk, hány $K \in \mathbb{N}^+$ klaszterbe csoportosítsa a pontokat
- fontos, hogy jól határozzuk meg az optimális klaszterszámot
- hasonlóan iteratív folyamat, melyhez felhasználunk egy ún. **objektív függvényt**

$$J_{KM}(U, V) = \sum_{i=1}^K \sum_{x_k \in C_i} \|x_k - v_i\|^2 = \sum_{i=1}^K \sum_{k=1}^n u_{ik} \cdot \|x_k - v_i\|^2$$

↓

ezt a függvényt kell minimalizálnunk

- a súlypontok / középpontok kiszámítása:

$$v_i = \frac{1}{|C_i|} \cdot \sum_{x_k \in C_i} x_k = \frac{\sum_{k=1}^n u_{ik} \cdot x_k}{\sum_{k=1}^n u_{ik}}$$

- előnyök

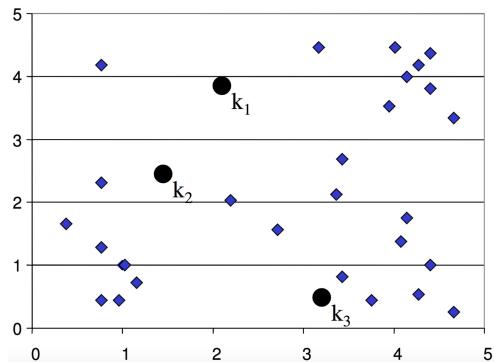
- egyszerű és könnyen implementálható
- intuitív objektív függvény
- relatíve hatékony: $\mathcal{O}(t \cdot k \cdot n)$
 - n : pontok száma
 - k : klaszterek száma
 - t : iterációk száma
 - jellemzően $k, t \ll n$

- hátrányok

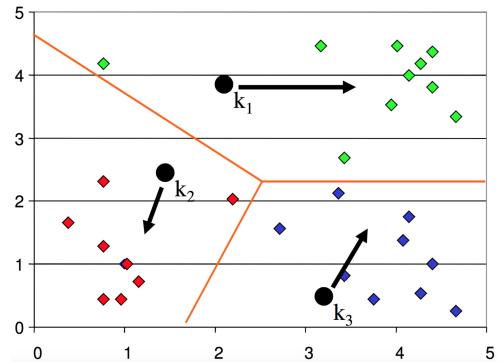
- alkalmazható, ha definiáljuk az átlagot
- muszáj meghatározni a K klaszterek számát
- vannak más távolságtechnikák, átlagszámítások
- sok esetben **lokális optimumban marad** (pl. nulla adatot tartalmazó klaszter)
- zajos és kirívó adatok kezelésére, valamint nem-konvex adatok felfedezésére sem alkalmas

- algoritmus

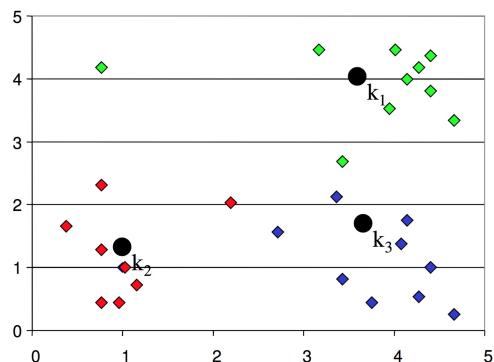
- léc: Határozzuk meg a klaszterek (K) számát. Legyen az adathalmaz $\{x_1, \dots, x_n\} \subseteq R^p$. Legyen továbbá t_{max} a maximum iterációk száma, $\|\cdot\|_v$ a klaszter középpontjától való távolság (norma), ε pedig a küszöbérték / tolerancia.
- léc: Inicializáljuk a klaszterek középpontjait random értékekkel. $V^{(0)} \subseteq R^p$
- léc: Döntsük el az összes (N) pontról, melyik osztályba tartozik (a legközelebbi középpontot hozzárendeljük). $U^{(t)}(V^{(t-1)})$
- léc: Újraszámoljuk a K klaszter középpontjait úgy, hogy feltételezzük, hogy a pontok a megfelelő partícióhoz tartoznak.
Ha $\|V^{(t)} - V^{(t-1)}\|_v \leq \varepsilon \Rightarrow$ véget ér az eljárás.
- léc: A 3-4. lépést addig ismételjük, ameddig egyik pontnak sem változik meg a partícióba való besorolása.
A végeredmény az U partíciómátrix és a V középpontok lesznek.



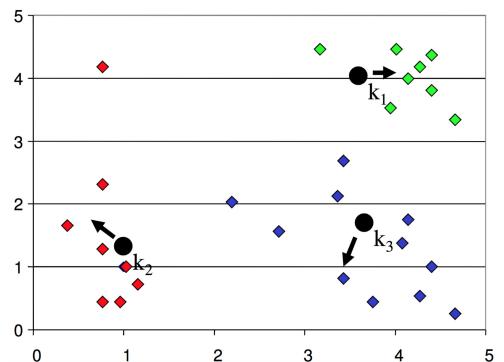
1. lépés: Inicializáció



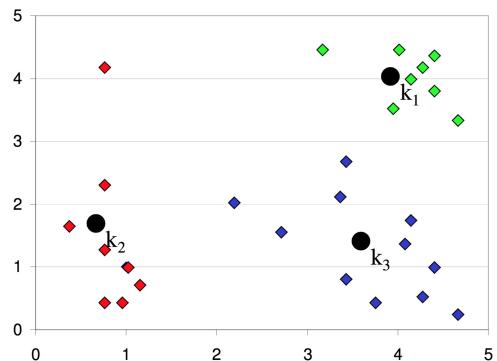
2. lépés: Pontok hozzárendelése klaszterekhez



3. lépés: Középpontok újraigazítása



2. lépés ismét



3-4. lépés (feltéve, hogy elértek a kívánt pontosságot)

6.2.3. DBSCAN

- angolul: *Density-Based Spatial Clustering of Applications with Noise*
- (nem volt róla részletesen szó)

6.3. Dimenziócsökkentés

- módszer: **főkomponens alapú analízis** (*principal component analysis*, PCA) – legfontosabb dimenziók megragadása
- statisztikus módszerrel az **n -dimenziós teret m -dimenziósra csökkentjük** ($m < n$)
 - azoktól szabadulunk meg, melyek a bemeneti tulajdonságokra nézve kis varianciájúak
- előnyei
 - kevesebb számítási idő, kevesebb adatot kell tárolni
 - redundanciát csökkenti
 - könnyű ábrázolni
- (nem volt róla szó részletesen az előadáson)

7. Megerősített tanulás

Angolul: *reinforcement learning* (RL)

7.1. Mi az a megerősített tanulás?

- ez áll a legközelebb ahhoz, ahogyan az emberek vagy állatok tanulnak
 - a kutya betanítása: ha ügyes volt, jutalomfalatot kap
 - csecsemők, babák tanulása a játszáson keresztül
- számítógépen: megközelítés arra, hogy interakciókból tanuljon a gép egy speciális **jutalomfüggvény** segítségével (*reward function*)

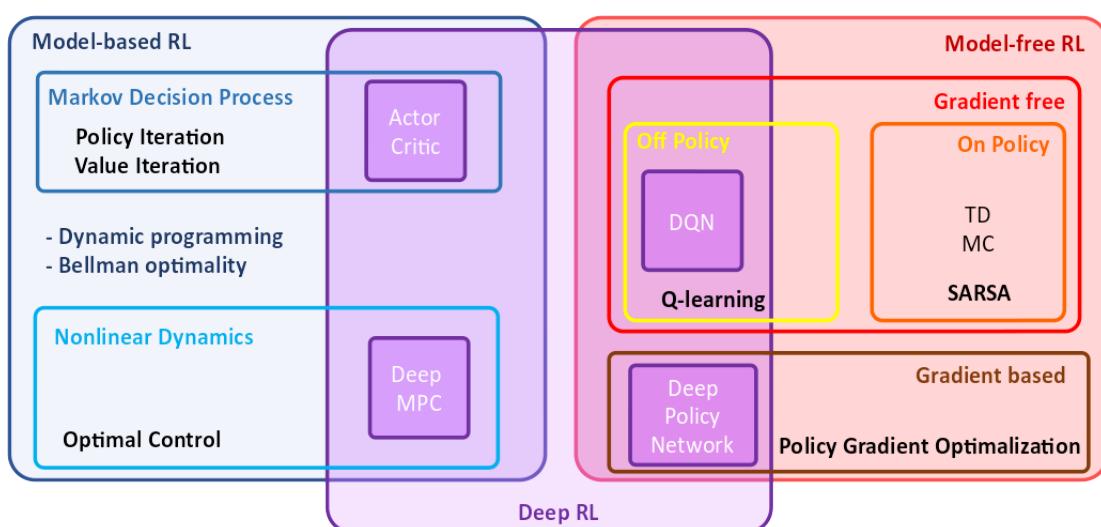
↓

helyzethez akciókat rendel → maximalizálja az érte járó jutalmat

- megoldható: próba-szerencse alapú kereséssel vagy késleltetett jutalmazással (állapotról állapotra lépegetünk)
- maga a fogalom 3 különböző dolgot fed le
 1. jelentheti magát a szóban forgó **problémát**, feladatot
 2. jelentheti a **megoldások osztályát** (amik jól megoldják a problémát)
 3. magát a **tudományterületet** (a feladatot és a megoldást tanulmányozza)

7.2. Háttér, ágazatai

- háttere, segítő tudományágak
 - az állati viselkedés pszichológiája (etológia)⁴, próba-szerencse módszerek
 - *optimális vezérlés* (*optimal control*), szenzorok, stb.
 - **játékelmélet** (általában diszkrét és folytonos)⁵
- ágazatai



17. ábra. A megerősített tanulás fajtái

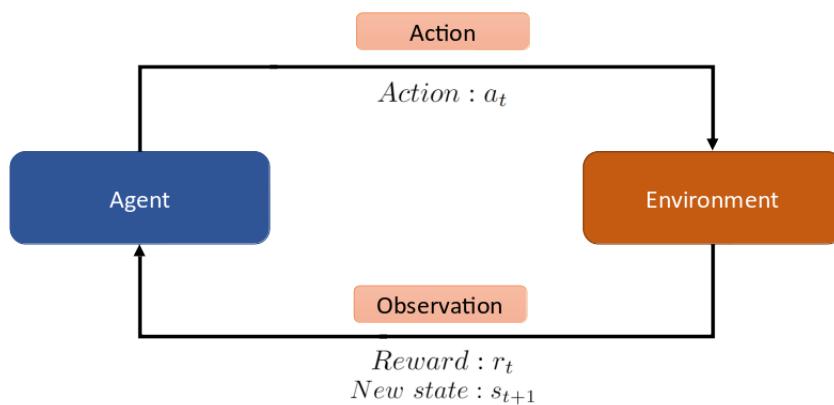
⁴Távolabbrá nyúlik vissza ugyan, de Pavlov kutyái és az ún. *feltételes reflex* is ideköthető.

⁵A sakk ideköthető példaként.

- Modell alapú RL: Markov döntési folyamat, dinamikus programozás, nemlineáris dinamikák
- Modellmentes RL: gradienscsökkentéses metódusok
 - *off-policy*: két külön térképen dolgozunk
 - *on-policy*: menet közben átirja a térképet

7.3. Felépítése

- **ágens (agent)**: akciókat hajt végre a *környezeten* → *Action* : a_t
 - **akció (action)**: egy mozgás, amit az ágens kiválthat a környezetében⁶
 - **akciótér (action space)**: a lehetséges akciók halmaza → $A = \{a_1, \dots, a_n\}$
- **környezet (environment)**: belőle megfigyelések (*observations*) áramolnak vissza az ágensbe, új állapotot és potenciálisan jutalmat eredményezve ezzel → *Reward* : r_t , *New state* : s_{t+1}
 - **jutalom (reward)**: az a visszajelzés, ami az ágens akciójának eredményességét számszerűsíti



18. ábra. A megerősített tanulás komponensei

- a térképen az *állapotok*, *akciók* és *jutalmak* együttese határozzák meg az ágens **trajektóriáját** (útvonalát); pl. az ábrán az ágens trajektóriája:

$$(S_{13} \rightarrow A_{right} \rightarrow R(+0)) \rightarrow (S_{14} \rightarrow A_{up} \rightarrow R(+0)) \rightarrow (S_{10} \rightarrow A_{right} \rightarrow R(+0)) \rightarrow \dots$$



19. ábra. Térkép

⁶Gondolhatunk egy videojáték játékosára és a lehetséges „műveleteire” (fel, le, ugrás, stb.)

7.4. Modell alapú RL – Markov döntési folyamat

Markov döntési folyamat (*Markov decision process*, MDP): Az MDP egy *diszkrét-idejű sztochasztikus*^a vezérlési folyamat.

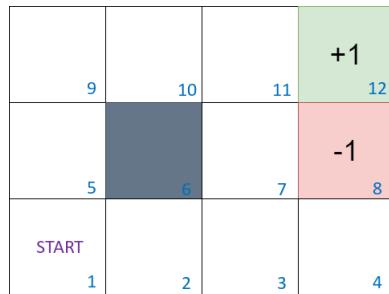
Egy matematikai keretrendszernyújt a döntéshozások modellezéséhez olyan helyzetekben, ahol a kimenetelek részben véletlenszerűek és részben a döntéshozó irányítása alatt állnak.

^aA sztochasztikus jelentése egy példán keresztül: ha jobbra megyek, nem garantált, hogy jobbra is megyek, de nagy esély van rá.

Az MDP **Markov-tulajdonságú**, ami annyit tesz, hogy annak a valószínűsége, hogy egy meghatározott állapotba váltsunk, kizártlag a jelenlegi állapottól és az eltelt időtől függ és független az idáig megtett állapotváltozások sorozatától.

- a feladat definíciója

- **Állapotok:** $S := \{1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12\}$
- **Modell:** $T(s, a, s') \sim \Pr(s' | s, a)$, ahol s' a rákövetkező állapotot jelöli⁷
- **Akciók:** $A(s), A := \{\text{up, down, left, right}\}$
- **Jutalom:** $R(s), R(s, a), R(s, a, s')$



[up, down, left, right]

20. ábra. A feladat térképe. A szürke mező falat jelent, amibe beleütközünk

- **stratégia** (angolul *policy*): az a függvényt, ami megoldja a problémát (annak definícióját), π -vel jelöljük. Az optimális stratégiát π^* -gal jelöljük
- a feladat megoldása
 - **Stratégia** (*policy*): $\pi : S \rightarrow A, \pi(s) = a$
- a modell lehet determinisztikus vagy nemdeterminisztikus (az összegnek 1-nek kell lennie)
 - determinisztikus példa:

$$\sum \Pr = 1 \iff \begin{cases} \Pr(s_5 | s_1, a_{\text{up}}) = 1 \\ \Pr(s_2 | s_1, a_{\text{up}}) = 0 \end{cases}$$

⁷Ez fogalmazza meg a Markov-tulajdonságot.

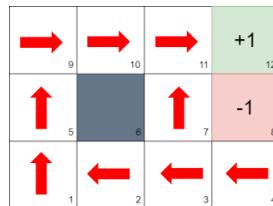
- nemdeterminisztikus vagy szochasztikus példa:

$$\sum \Pr = 1 \iff \begin{cases} \Pr(s_7 | s_1, a_{\text{up}}) = 0,8 \\ \Pr(s_4 | s_1, a_{\text{up}}) = 0,1 \\ \Pr(s_2 | s_1, a_{\text{up}}) = 0,1 \\ \Pr(s_1 | s_1, a_{\text{up}}) = 0 \end{cases}$$

pl. 80%-ban optimálisan viselkedek, de a maradékban meg ráhagyom a döntést a random faktorra → a szabadban **elengedjük felfedezi** a gépet

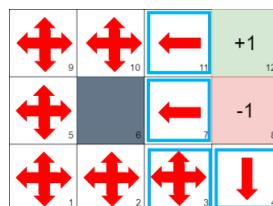
- példa

- A következő világnak az **optimális stratégiája** (*optimal policy*) az alábbi térképen látható, ahol az alapértelmezett jutalom $R(s) = -0,4$. minden lépés megtételével egy kicsivel csökken a jutalom, ezzel ösztönözzük, hogy ne maradjon egy helyben.



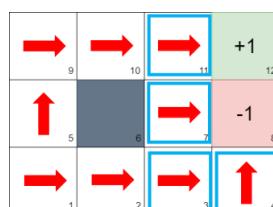
21. ábra. A feladat optimális stratégiája

- Jelöljük ki a 3-as, 4-es, 7-es, 11-es mezőket és ezekhez rendeljünk eltérő jutalmakat.
- Ha $R(s) = +2$, akkor az ágenst **felfedezésre** (**adatgyűjtésre**) **ösztönözzük**. Egy adott állapotban olyan akciót fog választani, amelyet még nem próbált ki. Emiatt nem feltétlenül azonnal fogja elérni a végső állapotot.



22. ábra. $R(s) = +2$

- Azonban ha $R(s) = -2$, akkor a **jutalom növelése érdekében** olyan akciókat fog választani, amelyeket korábban már kipróbált. Viszont így is szuboptimális stratégiát kapunk.



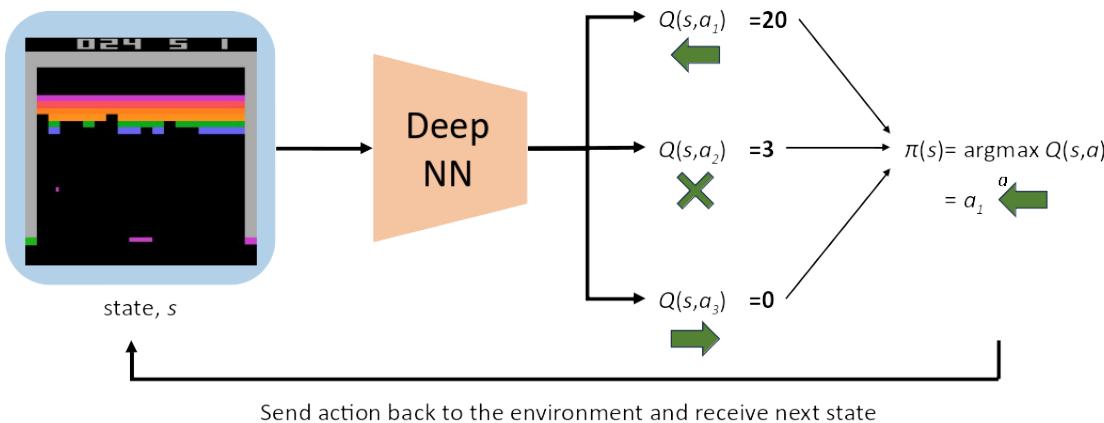
23. ábra. $R(s) = -2$

- Akárhogyan is, egy egyensúlyt kell kialakítanunk a két szempont között.

- **teljes jutalom** (*total reward*): $R_t = \sum_{i=t}^{\infty} r_i \rightarrow$ ekkora azonnali jutalmat kapunk, hogyha elérünk egy adott állapotot
- **diszkontált teljes jutalom** (*discounted total reward*): $R_t = \sum_{i=t}^{\infty} \gamma^i r_i \quad (\gamma \in [0, 1])$
(γ : diszkont faktor) $\rightarrow R_t = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \gamma^3 r_{t+3} + \dots$
- **Q -függvény**: a jövőbeli várható értékét ragadja meg az ágensnek az s_t állapotban úgy, hogy a_t akcióra számít
$$Q(s_t, a_t) = \mathbb{E}[R_t | s_t, a_t]$$
- ezt felhasználva megkaphatjuk az **optimális stratégiát** (*optimal policy, π^**)
$$\pi^*(s) = \arg \max_a Q(s, a)$$

7.5. Modellmentes RL – Mély RL algoritmusok

- két megközelítéssel oldhatjuk meg a feladatot
1. **Értéktanuló módszer**: keressük meg a $Q(s, a)$ -t $\rightarrow a = \arg \max_a Q(s, a)$
 - példa: **mély Q -hálózatok** (*deep Q networks, DQN*)
 - egy neurális hálót használunk a Q -függvény megtanulásához, amit majd felhasználunk az optimális stratégia kikövetkeztetéséhez



24. ábra. Érték tanulása az *Atari* videójáték példáján keresztül

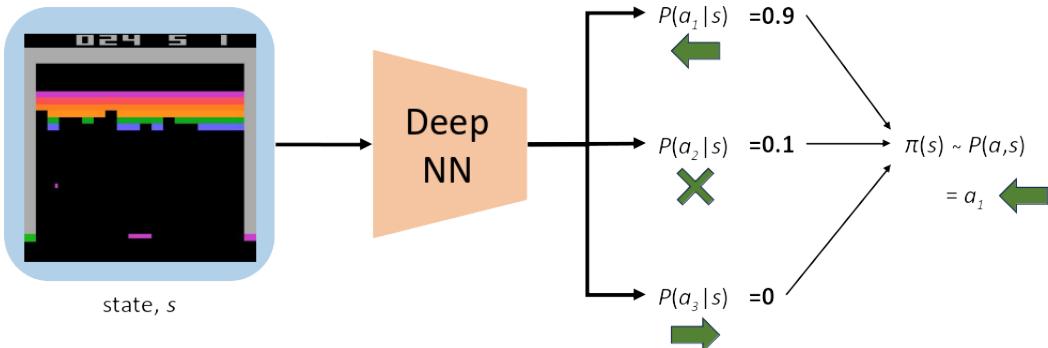
- előnyei
 - előnyös, ha az akciótér diszkrét és kevés elemből áll
- hátrányai
 - nem képes kezelni a folytonos akciótereket
 - a stratégiát determinisztikusan számítjuk ki a Q -függvényből a jutalom maximalizálásával, így szochasztkus stratégiákat sem képes megtanulni

↓

a felmerülő problémákat az RL tanító algoritmusok egy új osztályával küszöbölnétek ki **gradienscsökkentéses módszerekkel** (*policy gradient methods*)

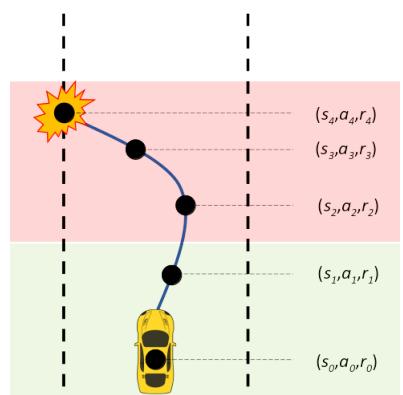
2. Stratégia-tanuló módszer: keressük meg a $\pi(s)$ -t \rightarrow a minta legyen $a \sim \pi(s)$

- gradienscsökkentés (*policy gradient*): közvetlenül optimalizáljuk a $\pi(s)$ stratégiát



25. ábra. Érték tanulása az *Atari* videojáték példáján keresztül

- kapunk egy eloszlásfüggvényt, amit paraméterezhetünk a szokásás μ -vel és σ^2 -tel (plusz még normalizált is) \rightarrow a diszkrét esetet könnyedén átvihetjük folytonosra
 - mivel a jelen példa diszkrét, ezért $\pi(s) \sim P(a, s) \leftarrow \sum_{a_i \in A} P(a_i | s) = 1$
 - diszkrét akciótér jelentése: „melyik irányba kell mennem?”
 - folytonos akciótér jelentése: „milyen gyorsan kell mennem?”
- előnyös megoldás, ugyanis könnyen írhatunk hozzá **szimulációt**
- tipikus példa: **önvezető autó**
 - algoritmus
 - Inicializáljuk az ágenst.
 - Addig futtatjuk a stratégiát, amíg nem terminál.
 - Rögzítsük a az összes állapotot, akciót, jutalmat.
 - Csökkentsük azon akciók valószínűségét, melyek alacsony jutalmat eredményeztek.
 - Növeljük azon akciók valószínűségét, melyek magas jutalmat eredményeztek.
 - A 4-5. lépésben a veszteséget így számíthatjuk ki: $loss = -\log P(a_t | s_t) \cdot R_t$.
 - Gradienscsökkentés: $w' = w - \nabla loss = w + \nabla \log P(a_t | s_t) \cdot R_t$
 - (f) Ismétlés.



26. ábra. Önvezető autó gradienscsökkentéssel

8. Biológiai alapú MI megoldások

8.1. Inspiráció, motiváció

- agy, evolúció(természetes kiválasztódás), rajointelligence
- swarm intelligence
- egyedül elég buta, viszont együttesen a problémamegodlási képességek erős
- mérnöki szempontból izgalmasak, mely kedvező tulajdonságai vannak
- nagy létszám esetén sorozatgyártott, egyszerűen összeszerelhető, olcsók, tök egyformák
- nincs főnökük *per se* (a királynő valójában csak egy elcseszett szülőgép, különösebben leszarja a boj életét)
- másik tul: nem kommunikálnak (emberi értékelben), nincs értekezlet, számonkérés, ÖNSZER-VEZŐDŐ módon működik →
- kellemesen függ a viselkedés a dolgozók számától → graceful degradation (méltóságteljesen csökken a teljesítmény); azaz ha meghal a boj fele, akkor fele olyan hatékonyak lesznek, nem fognak ilyen hülyeségekkel foglalkozni, mint hogy gyászoljanak, stb → alkalmazkodnak a környezethez; robosztusság

8.2. Rajointelligence – példák, motivációk

- Louis Rosenberg – Unanimous AI
- a méhek az esetek 80%-ában optimális helyet választanak rajon belül
- táncikálnak / kommunikálnak a levegőben : sok dimenzió szerint is optimalizálhatnak (úgy tűnik)
- etológusok adtak egy szigorú algoritmust, ami leírja a mozgásukat és az infósok bebizonyították, h megoldja a feladatot
- minél izgatottabb a méh / jobban jelzi, h menjenek oda a többiek, annál izgágábban táncolnak → gyűjt követőket, elviszi őket az új hejre → toboroznak még méheket
- minél többször megy egy hejre vki, annál kevésbé lelke (ráun xdd)
- mechanizmus a végén: ha bizonyos %-nál többen jönnek egy helyre → sípolással leállítja a többit és ...

8.3. Térbeli csoportosítás – spacial clustering

- hangyáknál cemetary organisation – egy helyre, kupacba rendezi az objektumokat (morzsa, golyó, pete, bigyó)
- erre is van egy egyszerűen leírható algoritmus, módszer
- két dimenziós rács, a hangyák véletlenszerűen közlekednek
- ahogy mennek, érzékelik, h mi van a környezetükben
- valamennyi memóriával rendelkeznek, h megnézzek, melyikből volt több idáig (piros, szörge)
- ha outlier találnak, az t áthelyezik a megelelő helyre
- lokális megfigyelés alapján optimalizáció
- egyszerű, de nagyon jól működik

8.4. Legrövidebb utak

- állítás: hangyák tudnának legrövidebb utat keresni két pont között
- nagyjából egyenes vonalban, de EGYMÁST KÖVETVE közlekednek
- közelisége a legrövidebb utak problémájának
- sztochasztikusan legrövidebb (nagyobb a valószínűsége, h rövidebb lesz,mintsem, h hosszabb)
- a) találunk kaját b) ha találtunk, leghatékonyabb aknázzuk ki (legközelebbi) c) legrövidebb úton szállítsul el
- megfigyelések: ha van választási lehetőség pathból, egyirányban a rövidebbet választják; akadályt raktak a legrövidebb útba aszimmetrikusan → a rövidebb úton kerülik ki
- erre is adtak matematikai modellt az etológusok, majd bebizonították a matekosok, h valóban megoldja a legrövidebb utak problémáját
- megoldás: feromonok (vmi, ami a fajtársakra hat – itt, élelem megtalálását segíti) → nem egymással, hanem az illatnymokkal kommunikálnak
- kétféle feromon: 1) ha keresi az élelmiszerforrást; 2) megvan a forrás és vissza akarja juttani a fészekbe
- a hazafele tartó olyat áraszt ki, amelyik mutatja, honnan hozta a kaját
- ILLÉKONY ANYAGOKRÜÓL VAN SZÓ
- illékony: terjed, eloszlik, de egyre gyengébb is lesz
- arra mennek, ahol a legerősebbnek érzékelik, de ezt sztochaszikusan (tehát nagyobb valószínűségű lesz az erősebb, de sosem biztos esemény) → viszont ameddig járkálnak az útvonalon, addig erős lesz a feromon (lasabban illik el); szóval a rövidebb útvonalat könnyebb megerősíteni, mint a hosszabbat;
- modellezhető 2d rácson
- erre alkottak absztrakt optimalizációs módszert (gráfokra értelmezett) → sok probléma megoldható vele
- marco dorigo

9. Evolúciós algoritmusok

9.1. Motiváció

- ha már MI, érdemes a TI-t (terézeszetes intelligencia) is tanulmányozni
- utánozzuk le az evolúciót
- fontos jelenség a tanulás → másoljuk le ezt
- további fontos fogalmak: versenyzés, reprodukció, raj(zás), kommunikáció – motivációként szolgálhatnak; ennek mesterséges létrehozása

9.2. Háttere, közös jellemzők

- bizonyos tanulásoknál a kiértékelések után tudunk változást létrehozni
- szemben az evolúciónál, a változások értékelődnek ki; melyből a jók élnek túl (evolúció = változások eredménye)
- ki él túl? aki a legjobban adaptálódik a környezethez
- keresési vagy tanulási problémák → megfalmazhatók optimalizációs feladatokként
- leegyszerűsíthetjük az optimalizációra a problémát
- megközelítések: determinisztikus (hegymászó algoritmus, analízis alapú deriválgatók faszságok); szochasztikus (véletlenkeresés, klasszikus szimulált lehűtés, evolúciós algoritmusok)
- klasszikus optimalizáció lokális optimalizációt hajt végre → találjuk meg ebből a globális optimumot
- egyedekbe kódoljuk be az optim. feladatot → ezek változnak az idő függvényében → egyre jobb megoldást adnak az adatoptimalizációs feladatra
- '50-es, '60-as évekre nyúlik vissza a gondolat
- ágai, iskolái: evolúciósprogramozás, ..., vmi nszk-s bigyó
- fogalmak: gén, allén, egyed, genotípus, fenotípus, poluláció,
- szétszórjuk az egyedeket (lehet sokdimenziós vektor) véletlenszerűen; bizonyos változások segítségével generációról generációra fejlődik az operáció → a globális optimum felé kezd sűrűödni a populáció

9.3. Genetikus algoritmusok

- 3 operátor. keresztezés, mutáció, szelekció
- minden egyedhez hozzárendelhetünk egy fitnessz értéket (jobb egyedeknek nagyobb szelekciós valószínűség)
- egyed: megoldása az adott problémára
- fitnesszérték: mennyire jó az adott egyed
- szekelciós módszerek: rulett-kerék alapú szelekció
- keresztezés: lehet bináris, intédzser, stb a kódolása → két szülőegyedet kiválasztunk, véletlenszerűen levágjuk őket, majd a két szülő két gyerekkel kapunk a szeletek kereszteződéséből (konkatenáció)
- mutáció: (pl. véletlenül megváltoztatunk egy bitet)

- példa: $f(x) := x^2$ ($x \in \{0, 1, \dots, 30, 31\}\right) =: I$, így $\max_{x \in I} f(x) \rightarrow$ 5-biten eltárolhatunk 32 számot (genotípus), fenotípusa ennek a bináris számnak a decimális alakja; populáció legyen 4.
- actual count: kiválasztások száma (ha 0, akkor az adott egyed kihalt)
- bizonyítható, hogy a határérték az optimum felé tart
- alternatív változatai: n -pontos keresztezés, uniformis keresztezés (maszksztringet definiálunk az érmefeldobásra, ha fej, cerélünk, ha írás, nem)
- ezt az ötletet viszi tovább: genetikus programok, genetikus programozás
- fákon (\rightarrow valójában programok, kifejezésfák) hajtják végre a műveleteket
- egy fa leír egy képletet (pl. fonya, yaaay)
- a fákon (ahogy korábban stringeken) hajtjuk végre az evolúciós algoritmust
- tekinthetjük úgy, hogy a fa a program és ezt optimalizáljuk (see: reverse Polish notation, prefix notation)
- függvény-node-ok : amik nem lehetnek levelek (tehát nemlevél csomópontok) $\{+, -, :, /, \%, IF\}$
- a többi meg szám
- mutáció: kiválasztunk egy függvénycsomópontot és rögzítjük váletlenszerű részfára cseréljük, vagy a levelet cseréli lege ygelőre definiált levélsúcsból
- keresztezés: kicséréli a részfákat
- a példa felügyelt tanulásos minta

10. Rajintelligencia

Ez a másik fajta evolúciós MI. Önállónak tekinthetjük akár, de van köze az előbbihez.

10.1. Bevezetés, motiváció

- biológia... mint az előző előadáson
- korábban szinte kizárolag matematikai megközelítéssel kutatták az MI-t
- ez eltolódott a biológia általi inspiráció felé
- kevésbé esett róla szó: kollektív intelligencia, egyedek közti kommunikáció
- stigmechia
- rajointelligencia
 - keresés és MI feladat megfogalmazható optimalizáció formájában
 - optimalizációs kritérium (felügyelet nélküli)
 - rendszerek együttműködése optimalizációt hajt végre basically
 - példák: madarak, halak, hangyák, méhek, stb.

10.2. Particle swarm optimisation (részecske raj optimalizáció)

- '90-es évek közepében jelent meg, azóta meg rendkívül dinamikusan fejlődő terület
- ágens, részecske; folytonos vektorként képzeljük el őket; valamilyen műveletet végeznek (pl erpülnék)
- pbesz: minden részecskére vontakozik, personal best, általa talált legjobb helyszín a repülés során
- gbest: globális legjobb
- ezek vezérlik az egyes részecskék repülését
- példa: k -adik iterációban a részecske eddigi legjobb és a raj eddigi legjobbjá

$$(gbest)^k$$

$$s^k \quad (pbest)^k$$

- tegyük fel, h aott van a $pbest^k$ értéke
- v^k a sebességvektora a részecskének
- a pbest és a gbest az, amik **kitérítik a vektor irányát**
- távolság a pbest és az s között: d^{pbest^k}
- ugyanez a gbest irányában is
- eredőjét számíthatjuk a kettőnek $\rightarrow v^{k+1}$ megkaojuk az új sebességet, vektort
- nagyon hatékony, egész egyszerű
- meghatározzuk a Δv^k -t, súlyozzuk ezeket (akár véletlenszerűséget is bevihetünk a súlyokba)
- $w_1 = c_1 \cdot rand()$ és $w_2 = c_2 \cdot rand()$ \rightarrow random generátor
- pozíciót és sebességet összeadhatunk a fizikában? ... végülis igen, mert diszkrét lépések vannak
- yaaay, kapunk stukiiit... csak szövegeset

- véletlenszerűen létrehozzuk az ágenseket / részecskéket / egyedeket → iterációk elteltével elkezdenek sűrűsödni egy adott pontban
- szokták versenyeztetni az ilyen függvényeket, benchmarkok

10.3. Simplified Swarm Optimisation

- egyed = vektorok; x_{ij}^{t+1} : x i -edik azonosítójának j -edik koordinátája a $(t + 1)$ -edik iterációban
- négy eset, más-más valószínűséggel választjuk, melyiket választjuk ($\rho \in [0, 1]$)
- ez is egyszerű, hatékony

10.4. Szentjánosbogár algoritmus (firefly algorithm)

- #define firefly
- mire használják a világításukat? → párzás, figyelmeztetési mechanizmus, áldozatok becserkészése
- fényintenzitást fogjuk használni a zalgorithmusban
- arányos lesz ez az attraktivitással, ami meg a távolsággal lesz fordítottan arányos
- I_0 : konstans érték, be van szorozva a két paraméter közti távolsággal
- mozgás: random mozgág + vonzóbb dolgok felé mozgás; egy α, β paramétert kapunk
- nem érdekesek az edgecase-ek

10.5. Gravitációs keresőalgoritmus

- minden egyednek van tömege; minél nagyobb a tömege, úgy vonzást számolhatunk, sebesség, stb., fizika
- számos ilyen algoritmus
- nem kell 100%-osan követni a valóságot, elég, ha csak őegy modellt állítunk fel
- $G(t)$
- erőhatás, Newton törtévnnye, gyorsulás mértéke
- a t az egy, mert diszkrét idő, tehát összeadhatunk sebességet és koordinátát
- az összes ilyen algoritmus STRUKTÚRÁJA
- paraméterezés, kezdeti populáció, fitnessz kiértékelés, fő működési mechanizmus, megolások frissítése, majd vége

11. Etorobotika

Etorobotika (*ethorobotics*) = etológia (viselkedéstan) + robotika

11.1. Motiváció

- több AI működik egy szerkezetben, robotban (beszédszintézis, feltérképezés, mozgás)
- cél: lényegében egy transzformer építése
- Vector (Anki szüleménye) – 4 magnyi processzor, mi, objektumdetekció, hangfelismerés, navigáció
- hogyan tervezünk olyan szociális robotokat, melyek napi szinten kapcsolatban vannak az emberrel
- viselkedéselemek pótlása
- érzelmeket hogyan pakoljuk bele (kezdetben macskaszerű volt)
- arckifejezésekhez érzelmeket azonosítunk
- mi a célja: robot integrálása emberi környezetbe, viszont nem várjatjuk el, h a környezet rendelkezzen programozói előképzettségekkel → robot viselkedése : etológia + robotika

11.2. Etorobotika

- motorikus funkciók (felemelni vmit) → viselkedésminták kialakítása (kockát felvesz, elvisz vhoval)
- viselkedés (játék: megkeres kockát, el kell vinni az emberhez) → érzelmek
- idegesség – gyors, heves mozdulatok
- fókuszáltság – lassabb, koncentráltabb

11.3. Etológiai mintánk

- KUTYÁK: jól integrálódtak, jól ismert viselkedésminták, hosszú évezredek tapasztalata
- kutatási és fejlesztési folyamat

etológiai kísérlet: ember–állat interakciója



etológiai viselkedésmodell



matematikai modell



robotvezérlés



etorobotikai kísérlet

- lényegében egy flowchart (gagyi struktogram) írja le a viselkedését
- egyszerű példa: napraforgó robot
- explicit megfigyelések alapul → hogyan tehetjük tanulhatóvá

11.4. Etológiai kutatási folyamat

- megfigyelések, rögzítjük
- nézzük, meddig csinálják az adott viselkedést
- teszt: Ainsworth-teszt: kötődés vizsgálata a kisgyerek és gondviselője között → etológusok ki-terjesztették ember-kutyára → robot-ember viszonyrendszerben visszamérhető-e?
 1. hozzászoktatás
 2. idegen megjelenik
 3. gazdi kimegy, első szeparáció
 4. első visszatérés, reunió
 5. kutya egyedül, második elkülönülés
 6. szeparáció folytatása az idegennel
 7. második visszatérés a gazdahoz
- definiálunk ey pontosabb mérőrendszert... ezeket rootok mérésére hogyan?
- amúgy ezt az előadó csinálta (wow)
- nemcsak, h mit szeretnénk mérni az állaon
- mit tudunk belerakni a robotba? top-down (tudjuk, h mit csináljon a robot, ezt kell megvalósítani), bottom-up (szenzorok, motorok → na, együtt mire képesek?)
- borzongások völgye (uncanny valley), emberszabádú robotoknál jelent meg
- csak azért tegyünk be valamit, ha van funkciója (a roboton a realisztikus bőr nem az, mert az embernek a legnagyobb érzékszerve, de a robot nem használja)
- feature matching

11.5. Kísérletek

- Biscee (kék): felszolgáló robot, kommunikáljon a vendégekkel
- Ethon (piros)
- differenciált ???-vel rendelkeztek
- mecanumbot, raspberry pi, jobban modellezhetők az állati mozgások, a számításigényes műveleteket kirendelhetjük egy szervernek (amin a nagy nyelvi modell van pl.)
- külső megfigyelő rendszer: MoCap (CGI, motion capture system, filmekben használják)
- mozgásnak leképezése, matematikai modellje
- robohoz rögzített koordináta rendszer jobb választás volt, mint egy abszolút koordrend
- etogrammok kitöltése, sokkal pontosabbak egy robot esetében (hatékonyabb is, mint amit az etológusok végeznek)

12. Multiágens szimuláció és tanulás (Multi-agent simulation and learning)

Inkább érdekességeként szerepel az előadásban.

12.1. Motiváció

- gyakori képzet, hogy „egy nagy valami egy nagy dolgot végez el”
- ezzel szemben ez egy többszereplős rendszer (ahogy a világ is az általában)
- „két mesterséges intelligencia beszélget...”
- néha ügynöknek is nevezik, ám ez félreérthető
- ágens: olyan szereplő, ami saját maga rendelkezik a cselekedeteiről (autonómia)
- láttunk hasonlót: foraging ants (hangyák)
- kooperáció vagy versenyhelyzet
- szorosan kapcsolódnak játékelméleti gondolatok

12.2. Mikro- és makroviselkedés

- többszereplős rendszereknél eme két szintet szoktuk vizsgálni: mikro (egyes szereplők) és makro (a teljes rendszerszintű működés)
- felfedezhetünk érdekes, előre be nem látható következményeket a rendszer szintjeiben
- ilyenek pl. az emergens tulajdonságok (megjelenő, előbújó)
- individuálisan egyik egyed sem rendelkezik vele (pl. dugóval), viszont egy nagy rendszerben már megjelenhet
- két féle megközelítés:
- ágens-alapú szimuláció (analízis): adott pár mikroszabály az egyedek szintjén, melyek makro szinten generálnak makroviselkedést → egy eszköz vminek a megmagyarázásához
- multiágens (megerősítéses) tanulás (konstrukció): kooperálni, rajzani tanulnak meg

12.3. Ágens alapú szimuláció

- klasszikus példa: detroitban szegregáltan élnek → miért van? ... nehezen ellenőrizhető dolgokat sorakoztatunk fel; eme tesztelés nélküli véleményeket vizsgálhatjuk az alábbi módon
alkotunk egy szabályrendszert, szimulációt, modellt és nézzük meg, hogy a jelenség emergál-e
- funky közgazdasz: mátrixot rajzolt fel, egy négyzetrács egy lajhelyt jelent, kék és piros "családok" (vagy üres) laknak benne. időközönként megyizsgálják, hogy hány velük azonos színű lakik a szomszédukban. ez lesz a toleranciája, ha ezt megüti, akkor elköltözik
- továbbra is mindenki marad a helyükön, ha 70%-a → továbbra is előbújnak eme szegregációk
- megmutatja, hogy a szegregáció egy rendkívül erős emergens jelenség
- hasonlót vizsgáltak már vírusterjedést, birkanyájakat

12.4. Multiágens megerősített tanulás

- mi van, ha több genst szeretnék egyszerre tanítani?
- cél, hogy közösen oldjanak meg egy problémát

- a) vannak benne specialisták (designer, projekvezető, tesztelő, fejlesztő)
- b) mindenki egyforma és közösen küzdenek a probléma megoldásáért, nincs hierarchia, csupán egymást érzékelve dolgoznak (extra: lehessen számtól független, magyarán fele annyi egyeddel is kezdhessünk valamire)
- vesszük ezeket az üres agyú robotokat, megfogalmazunk nekik egy (egyszerű) feladatot (általában egymáshoz képest mozgási feladatok – álljanak libasorba)
- közlekedési lámpák vezérlése, calen szinkronizációja